PROGRAMA DE PÓS-GRADUAÇÃO EM TECNOLOGIAS COMPUTACIONAIS PARA O AGRONEGÓCIO (PPGTCA / UTFPR)

SAREL: Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar
Um Instrumento Computacional Auditável para Amostragem Estratificada, Curadoria Temporal Orbital e Gestão de Rotulagem Cega no Paraná

Mestrando: Luis Alfredo
Programa: PPGTCA / UTFPR

Área de Concentração: Tecnologias Computacionais para o Agronegócio
Recorte Territorial: Macrobacias Hidrográficas do Paraná

Natureza: Instrumento de Apoio Metodológico
Finalidade: Suporte à Pesquisa de Mestrado

PPGTCA / UTFPR • Tecnologias Computacionais para o Agronegócio • 2026 Luis Alfredo • Mestrando

A Natureza Difusa do Fenômeno

Remoção Contínua e Silenciosa: A erosão laminar remove lâminas delgadas de solo fértil de maneira distribuída, sem a formação imediata de incisões ou sulcos visíveis na superfície cultivada.

O Limite da Vistoria Tradicional: Vistorias presenciais convencionais sofrem com viés de proximidade a rodovias, subjetividade do operador, ausência de rastreabilidade temporal e cobertura restrita a frações mínimas do território.

Tensão Metodológica Real: Se a erosão laminar é um processo de dano cumulativo difuso, a fotointerpretação remota instantânea é desafiadora. O sensoriamento remoto não substitui a física de campo, mas captura seus efeitos acumulados na série histórica.

A Resposta do SAREL: Detecção por Indicadores

Assinaturas Espectrais Indiretas: O sistema rastreia na série Sentinel-2 os indicativos biofísicos consolidados na literatura internacional:

• Decapitação do Horizonte A: Exposição de solo mineral com maior reflectância no SWIR e elevação do BSI (Bare Soil Index);

• Persistência de Exposição (Ê): Frequência multitemporal de solo descoberto na entressafra
e rotação de culturas;

• Perda Fenológica: Depressão anômala nos picos sazonais de NDVI modelados por análise
harmônica (OLS).

Validação Concorrente Obrigatória: O rótulo orbital é auditado por amostragem presencial
de marcadores diretos (pedestais, crostas e descalçamento radicular) com RTK.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 2 / 14

Comparação entre Estratégias Amostrais
Cenário A (100% Presencial em Campo):
• Exigiria 250 a 300 pontos visitados por equipe com GNSS RTK;
• Custo orçado entre R$ 75 mil e R$ 120 mil (deslocamento, diárias, combustível, equipe e dispersão geográfica no PR).
Cenário B (100% Sintético / RUSLE):
• Rejeitado por vício metodológico estrito: Treinar ML sobre dados gerados pela própria equação RUSLE levaria o algoritmo a meramente reaprender a equação, gerando resultados ilusórios sem validade empírica.
Cenário C (Híbrido Proposto pelo SAREL):
• Amostragem remota estratificada de alta resolução (~80%) conjugada à validação presencial em subamostra de controle (~20%).

Memória de Cálculo & Considerações Estatísticas
Potencial de Redução de Custo:
• A estimativa orçamentária aponta redução de até ~80% nos custos de amostragem perante o cenário puramente presencial. Trata-se de estimativa operacional, e não economia contabilmente comprovada a priori.
Tamanho Amostral & Risco de Sobreajuste:
• Em algoritmos de árvores com gradiente (XGBoost), amostras pequenas geram risco clássico
de alta variância e sobreajuste (overfitting), exigindo controle de hiperparâmetros e validação espacial cruzada.
• O dimensionamento para 250–300 pontos visa manter representatividade mínima dentro dos
18 estratos biofísicos e assegurar suporte estatístico robusto na partição LOCO por bacias.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 3 / 14

1. Propor Onde Observar

• Particionamento do Paraná em 18 estratos biofísicos
cruzando relevo, solo e histórico de exposição;
• Rarefação espacial determinística (d ≥ 1 km) com
semente pública para mitigar agrupamento excessivo;
• Amostragem representativa cobrindo encostas críticas e áreas sob Sistema Plantio Direto consolidado.

2. Extrair com Rastreabilidade

• Extração de preditores em SIRGAS 2000 / UTM 22S a
partir do Copernicus DEM (30m) e Sentinel-2 (10/20m);
• Decomposição harmônica OLS de 10 anos e métricas de solo exposto com proveniência por valor;
• Consulta pedológica oficial via WFS OGC do GeoServer da Embrapa Solos.

3. Gerenciar Rotulagem Cega
• Geração de cadernos de rotulagem cegos (sem acesso
a previsões, declividade ou escores internos);
• Avaliação de validade concorrente via Kappa de Cohen
com IC 95%;
• Princípio de Demarcação: O treino do modelo preditivo é
externo; o SAREL prepara a matriz e gerencia os dados.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 4 / 14

Regras 1, 5 & 4: Dado Real & Demarcação
Regra 1 & 5 — Proibição de Constantes:
• Terminantemente vedado preencher lacunas de satélite com médias arbitrárias ou funções unmask com valores fixos;
• Nulos são preservados com a causa da ausência e tratados nativamente pelo XGBoost;
• Zero é valor físico legítimo (ex.: declividade 0% ou Ê = 0) e nunca é colapsado para ausente. Regra 4 — Princípio de Demarcação:
• Nada calculado pelo software vira rótulo de treino;
• A perda estimada pela RUSLE e escores internos são excluídos da matriz de treinamento do XGBoost.

Regras 3 & 9: Proveniência & Registro
Regra 3 — Tríade de Metadados por Valor:
• Cada número carregado no sistema é acompanhado por: estado, fonte primária oficial e data de aquisição;
• Quatro Selos Formais: medido (sensor primário), modelado (equação física), tabelado (literatura de referência) ou indisponível (com causa formal declarada).
Regra 9 — Transparência Decisória:
• Todo limiar científico é registrado formalmente no arquivo DECISOES.md com autor, data e
fundamentação bibliográfica;
• Parâmetros ainda não homologados pelo pesquisador permanecem bloqueados como 'indisponível'.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 5 / 14

Particionamento em 18 Estratos Físicos
Estrutura do Espaço Amostral:
• ■ (Terreno): 3 tercis empíricos de declividade calculados sobre a área de estudo;
• Ê (Exposição): 3 tercis de frequência multitemporal de solo descoberto na série Sentinel-2;
• K■ (Erodibilidade): 2 níveis derivados do levantamento pedológico 1:250.000 da Embrapa Solos (Nível 1: baixa/média erodibilidade; Nível 2: alta/muito alta erodibilidade).
• Total: 3 (■) × 3 (Ê) × 2 (K■) = 18 estratos independentes para distribuição balanceada dos pontos candidatos.

Rarefação Espacial & Blindagem contra Circularidade
Rarefação Espacial Gulosa (Thinning):
• Impõe espaçamento mínimo de d ≥ 1,0 km (distância esférica de grande círculo via Haversine) para evitar agrupamentos sobre a mesma vertente ou talhão;
• Ordenação pseudo-aleatória determinística por Fisher-Yates com semente registrada (P07),
garantindo reprodutibilidade estrita.
Enfrentamento da Circularidade Seleção × Preditores:
• A estratificação define onde observar para cobrir todo o espectro de relevo e solo do Paraná;
• A atribuição de Classe 1 (erosão) ou Classe 0 (controle) decorre exclusivamente do rótulo humano independente, sem pré-classificação algorítmica forçada na matriz.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 6 / 14

Insumos de Terreno e Espectrais
Modelo Digital de Elevação (Copernicus DEM GLO-30):
• Reprojetado para SIRGAS 2000 / UTM 22S (EPSG:31982), eliminando o erro de distorção de escala sec(φ) do Web Mercator que subestima declividades no Paraná em até ~10%;
• Derivação de curvatura de perfil, curvatura plana e acúmulo de fluxo.
Série Multiespectral Sentinel-2 L2A (BOA):
• Bandas B2, B4, B8 (10m) e B11, B12 (20m com reamostragem bilinear para alinhamento na grade de 10m);
• Máscara de nuvem e sombra via Scene Classification Layer (SCL), preservando lacunas sem reposição artificial.

Decomposição Harmônica & Discriminação de Solo Nu
Modelo Harmônico OLS (Zhu & Woodcock, 2014):
• Regressão por mínimos quadrados de 1 e 2 ciclos anuais sobre a série histórica, modelando tendência, amplitudes sazonais e fases para cada banda;
• Métricas de qualidade: número de observações válidas, erro-padrão e coeficiente de determinação R².
Discriminação Solo Nu × Palhada Seca em SPD:
• Em Sistema Plantio Direto, palhada residual seca apresenta baixo NDVI. O SAREL conjuga
NDVI com BSI e bandas SWIR para evitar que talhões bem cobertos com palhada morta sejam
falsamente computados como solo exposto degradado.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 7 / 14

RUSLE como Comparador Externo
Papel na Pesquisa:
• A equação empírica RUSLE (A = R · K · LS · C · P) atua exclusivamente como linha de base comparativa;
• Não fornece rótulos supervisionados e sua perda estimada não integra os preditores da matriz de treinamento do XGBoost.
Fator C Decidido (D01):
• C = (1 − NDVI)/2 (Durigon et al., 2014). Equação sem parâmetros livres ajustada para bacia tropical;
• Limitação conhecida: resposta linear comprime a faixa de C em dossel fechado; análise de sensibilidade com van der Knijff et al. (2000) prevista no plano.

Fatores Pendentes & Invariante 1
Fator P Tabelado:
• P = 1,0 (práticas conservacionistas desconhecidas, Renard et al., 1997). Ajustável exclusivamente se houver comprovação documental de terraços em campo.
Fatores R, K e LS em Decisão (D13, D14, D15):
• Status Sincero: Os fatores R (erosividade pluviométrica), K (erodibilidade numérica em Mg·h·MJ■¹·mm■¹) e LS (topografia bidimensional) estão em calibração;
• Invariante 1 Ativo: O cálculo de perda de solo é formalmente mantido como 'indisponível'
pelo sistema até que todas as decisões sejam homologadas pelo pesquisador.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 8 / 14

Identificação Institucional das Bases
Distinção e Origem dos Cadastros:
• SICAR: Cadastro Ambiental Rural (559.899 polígonos no Paraná, base autodeclaratória pública);
• SIGEF: Parcelas georreferenciadas certificadas pelo INCRA (Lei nº 10.267/2001);
• SNCR: Sistema Nacional de Cadastro Rural, instituído pela Lei nº 5.868/1972 e administrado pelo INCRA (não pela Receita Federal, cujo cadastro fiscal é o CAFIR).
Finalidade Exclusiva:
• Logística e autorização de entrada prévia da equipe de vistoria de campo junto aos proprietários.

Conformidade Jurídica & Proteção de Dados
Base Legal Invocada:
• Tratamento fundamentado no Art. 7º, IV da Lei nº 13.709/2018 (LGPD): realização de estudos por órgão de pesquisa (UTFPR), com controladoria e finalidade delimitadas. Medidas de Segurança Operacional:
• Nomes e documentos são pseudonimizados/mascarados byte a byte em consultas de tela e
perfis exportados;
• O acesso a contatos de titulares para autorização de entrada em campo é restrito a sessões
autenticadas do pesquisador;
• O sistema substitui retórica de 'imunidade total' por conformidade técnica estrita e mitigação
de riscos sob a LGPD.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 9 / 14

Fases de Rotulagem Cega e Campo
Fase A — Interpretação Cega (VHR / PlanetScope 3m / Ortofoto):
• Fotointérpretes avaliam sinais de superfície (decapitação, carreadores, falhas de plantio) sem acesso a previsões de modelos, declividade ou escores.
Fase B — Vistoria de Campo Concorrente (Subamostra ~20%):
• Equipe com GNSS RTK e KoboToolbox avalia marcadores biofísicos diretos de campo (pedestais, crostas superficiais e descalçamento radicular).
• Cegueira Cruzada: A equipe de campo desconhece o rótulo atribuído na Fase A.
Fase D — Conjunto Held-Out de Alta Resolução:
• Ortomosaicos de drone em sítios de referência isolados estritamente para teste.

Auditoria de Concordância Kappa com IC 95%
Significado Científico do Kappa:
• Mede a validade concorrente entre a rotulagem orbital remota (Fase A) e a verdade de campo (Fase B);
• O sistema calcula o Erro-Padrão assintótico e o Intervalo de Confiança de 95% (IC 95%), fornecendo suporte estatístico robusto contra variações amostrais.
Patamar de Bloqueio (Landis & Koch, 1977):
• Trava operacional exige κ ≥ 0,61 (patamar substancial).
Tratamento de Divergências:
• Casos divergentes são arbitrados por perito sênior ou mantidos com marcação de incerteza,
evitando o expurgo cego de instâncias de fronteira difícil.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 10 / 14

Validação Espacial por Macrobacias (LOCO)
Quebra da Autocorrelação Espacial:
• A Primeira Lei de Tobler (pontos próximos são mais parecidos entre si) inviabiliza a validação K-Fold aleatória tradicional em dados espaciais;
• O particionamento Leave-One-Cluster/Basin-Out (LOCO) treina o XGBoost em 4 bacias hidrográficas e testa na 5ª bacia omitida, avaliando a capacidade de generalização territorial real do modelo preditivo.
Remoção de Coordenadas da Matriz:
• Latitude e longitude são terminantemente excluídas das variáveis de treino para impedir sobreajuste por memorização espacial geográfica.

Métricas de Avaliação & Explicabilidade Física
Discriminação vs Calibração Probabilística:
• ROC-AUC mede exclusivamente a capacidade de ordenação (discriminação) entre classes;
• A confiabilidade das probabilidades preditas é avaliada por métricas formais de calibração (Curvas de Calibração e Brier Score).
Auditoria de Coerência via SHAP:
• Gráficos Beeswarm e Dependência Parcial (valores de Shapley) explicam a contribuição biofísica das árvores do XGBoost;
• Permite auditar se o modelo fundamenta suas decisões em declividade e cobertura ou se está capturando artefatos indesejados.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 11 / 14

As Sete Travas Formais de Integridade do SAREL
Invariante 1 — Coerência RUSLE: Perda de solo só é exportada se todos os 5 fatores e a memória de cálculo existirem. Caso contrário, permanece bloqueada.
Invariante 2 — Lista de Permissão por Perfil: Bloqueia colunas não autorizadas e impede o vazamento de escores internos e variáveis sensíveis.
Invariante 3 — Rastreabilidade de Campos Não Medidos: Registra a lista explícita de campos cujo estado não seja 'medido' por sensor primário.
Invariante 4 — Metadados de Rastreio Orbital: Toda exportação registra identificador da cena Sentinel-2, versão do motor e timestamp.
Invariante 5 — Afirmação Negativa Fundiária: O status 'sem correspondência' só pode ser declarado após consulta bem-sucedida sem match.
Invariante 6 — Lista Negra de Literais Geográficos: Bloqueia nomes de UF no campo de município ou descrições provisórias de programa ('Custom', 'Bacia Local').
Invariante 7 — Detector de Constante Disfarçada: Bloqueia colunas com valor idêntico em 100% das linhas quando N ≥ 21, com exceção explícita auditada para colunas tabeladas legítimas (ex.: Fator P = 1,0).

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 12 / 14

Limitações Metodológicas Declaradas
1. Resolução Espacial do MDE (30m): O Copernicus DEM suaviza feições de microrrelevo (pequenos terraços e sulcos decamétricos) que influenciam o escoamento superficial direto.
2. Janela Óptica & Cobertura de Nuvens: A frequência de nebulosidade no Paraná limita a quantidade de cenas utilizáveis sem interferência atmosférica.
3. Viés de Acesso em Campo: A subamostra presencial de 20% depende de autorização de proprietários, podendo gerar viés de consentimento nas vistorias.
4. Parametrização RUSLE em Andamento: A linha de base ainda aguarda a homologação formal dos fatores R, K e LS para emissão de perda em t/ha/ano.

Status Atual do Sistema & Próximos Passos
Realidade Operacional Atual do SAREL:
• Módulos de amostragem estratificada, banco fundiário local, cliente OGC Embrapa e governança de invariantes 100% implementados e testados.
Cronograma da Pesquisa de Mestrado:
• Fase 1: Execução da rotulagem cega (Fase A) sobre imagens de alta resolução;
• Fase 2: Campanha de campo (Fase B) e auditoria Kappa de concordância;
• Fase 3: Homologação dos fatores pendentes da RUSLE (R, K, LS);
• Fase 4: Treinamento do XGBoost com validação LOCO e redação final.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 13 / 14

Fundamentação Teórica da Metodologia e dos Algoritmos
Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1), 37-46.
Demattê, J. A. M. et al. (2018). Geospatial Soil Sensing System (GEOS3): A tool for soil mapping and environmental assessment. Geoderma, 325, 1-20.
Durigon, V. T. et al. (2014). NDVI time series for monitoring RUSLE cover management factor in a tropical watershed. Int. J. of Remote Sensing, 35(2), 441-453.
Fleiss, J. L., Cohen, J., & Everitt, B. S. (1969). Large sample standard errors of kappa and weighted kappa. Psychological Bulletin, 72(5), 323-327.
Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1), 159-174.
Renard, K. G. et al. (1997). Predicting soil erosion by water: a guide to conservation planning with the Revised Universal Soil Loss Equation (RUSLE). USDA Agriculture Handbook 703.
Roberts, D. R. et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical or phylogenetic structure. Ecography, 40(8), 913-929.
Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. Economic Geography, 46, 234-240.
Zhu, Z., & Woodcock, C. E. (2014). Continuous change detection and classification of land cover using all available Landsat data. Remote Sensing of Environment, 144, 152-171.

SAREL v2.0 • Sistema de Amostragem, Sensoriamento e Rotulagem para Predição de Erosão Laminar no Paraná 14 / 14