

COMPÊNDIO METODOLÓGICO SAREL v2.0

Guia Didático e Pericial de Fundamentos, Desenho Amostral, Sensoriamento Remoto, Inteligência Fundiária e Modelagem Preditiva para a Pesquisa de Erosão Laminar no Paraná

Autor / Mestrando: Luis Alfredo Ferreira da Silva

Orientador: Prof. Dr. Claudio Leones Bazzi

Linha de Pesquisa: Geotecnologias Aplicadas e Modelagem Computacional no Agronegócio

Sistema Computacional: SAREL v2.0 (Sistema de Amostragem e Rotulagem para Erosão Laminar)

Finalidade do Documento: Guia de aprofundamento e assimilação metodológica para defesa de qualificação e dissertação de mestrado.

[CONCEITO FUNDAMENTAL] Como Estudar e Introjetar Este Documento

Este compêndio foi estruturado em sequência lógica e cronológica estrita — desde a física do solo até os algoritmos de aprendizado de máquina. Cada capítulo dissecar: (i) o **conceito teórico**; (ii) a **fórmula matemática**; (iii) a **implementação computacional** no código do SAREL; e (iv) as **armadilhas e defesas** perante a banca examinadora do PPGTCA. Recomenda-se a leitura atenta dos quadros de destaque.

Capítulo 1: O Fenômeno Físico da Erosão Laminar e a Escala do Paraná

1.1 O Mecanismo Biofísico da Erosão Laminar (Sheet Erosion)

A erosão hídrica laminar é a remoção aproximadamente uniforme de delgadas camadas de solo da superfície do terreno, impulsionada pela ação conjugada de dois agentes físicos: o impacto das gotas de chuva (*splash detachment*) e o deflúvio superficial difuso e não concentrado (*sheet runoff*). Ao contrário da erosão em sulcos (*rill*) ou voçorocas (*gully*), a erosão laminar não produz incisões topográficas imediatamente visíveis ao olho destreinado ou em fotos aéreas de baixa resolução.

Durante o impacto pluviométrico, a energia cinética das gotas desagrega os agregados do horizonte superficial, provocando o selamento superficial dos poros (*soil crusting*). Essa crosta impermeabilizante reduz drasticamente a taxa de infiltração de água no perfil do solo. O excedente pluviométrico gera uma lâmina líquida de alta turbulência que transporta preferencialmente a fração argila, a matéria orgânica e os nutrientes adsorvidos (fósforo e potássio).

[CONCEITO FUNDAMENTAL] Por que a Erosão Laminar é o 'Perigo Invisível' da Agricultura Tropical?

Em lavouras sob preparo convencional ou com cobertura vegetal deficiente, um talhão agrícola pode perder de 15 a 40 toneladas de solo por hectare ao ano sem apresentar uma única fenda no terreno. Uma perda de 30 t/ha/ano equivale ao desaparecimento de aproximadamente 2,5 a 3,0 mm da camada mais nobre e fértil do solo por safra. Quando os sulcos finalmente surgem na paisagem, dezenas de anos de fertilidade natural já foram carregados para o leito dos rios.

1.2 A Escala Regional do Paraná (199.315 km²)

O Estado do Paraná apresenta uma das geografias agrícolas mais complexas e produtivas do mundo, distribuída em 199.315 km² e marcada por fortes contrastes pedológicos e topográficos. A pesquisa exige compreender essas três grandes províncias:

- **Arenito Caiuá (Noroeste Paranaense):** Solos arenosos profundos (Neossolos Quartzarênicos e Latossolos Vermelhos distróficos), extremamente frágeis à erosão e com baixíssimo teor de argila. Requerem monitoramento constante.
- **Terceiro Planalto Basáltico (Norte/Oeste - Londrina, Maringá, Cascavel):** Solos argilosos e muito argilosos (Latossolos Vermelhos e Nitossolos Eutróficos), altamente estruturados e férteis, porém sujeitos a escoamento superficial volumoso devido a chuvas torrenciais convectivas.
- **Primeiro e Segundo Planaltos (Centro-Sul/Campos Gerais):** Relevo ondulado a escarpado, com solos mais rasos (Cambissolos) e gradientes de rampa elevados que amplificam a velocidade da enxurrada.

1.3 O Dilema dos Custos de Amostragem: A Justificativa da Abordagem Híbrida

Para treinar um modelo de aprendizado de máquina supervisionado capaz de prever áreas suscetíveis à erosão em escala estadual, a literatura exige um conjunto de dados de 250 a 300 instâncias devidamente rotuladas. Aqui surge o gargalo decisivo enfrentado pelo pesquisador de mestrado:

Abordagem	Custo Estimado	Viabilidade no Mestrado	Rigor Perante a Banca
100% Campo (Visita física a 300 pontos)	R\$ 75.000 a R\$ 120.000 (Combustível, 4x4, diárias, GNSS RTK, 4 a 6 meses de viagem)	Inviável Tempo e orçamento incompatíveis	Alto rigor, mas amostra real reduzida (N < 40) causaria subajuste (underfitting).
100% Sintético (Simulação por equações/regras)	R\$ 0,00 (Cálculo puramente computacional)	Imediata Gera números em segundos	Nulo / Rejeição Sumária Vazamento de alvo: o modelo memoriza fórmulas e não aprende o mundo real.

Estratégia Híbrida SAREL (Fotointerp. VHR 80% + Campo 20%)	Redução de ~80% no custo (Viável com recursos acadêmicos normais)	100% Exequível Dentro do cronograma de 2 anos	Blindagem Total Estatística de concordância (Kappa de Cohen) valida cientificamente a rotulagem.
--	--	---	--

[ATENÇÃO PARA A BANCA] Como Justificar a Abordagem Híbrida na Qualificação e na Defesa π

'A amostragem 100% em campo é logisticamente impraticável em escala estadual no Paraná, enquanto o dado 100% sintético é metodologicamente inválido. O SAREL resolve o dilema adotando fotointerpretação padronizada em alta resolução (VHR) ancorada em uma subamostra presencial de calibração física de 20%. A acurácia dessa rotulagem remota é comprovada matematicamente pelo Índice Kappa de Cohen, assegurando que o treinamento do XGBoost ocorra sobre verdades observacionais auditáveis.'

Capítulo 2: O Desenho Amostral — Critérios de Obtenção e Seleção

2.1 O Frame Territorial e a Máscara de Elegibilidade

Nenhum ponto amostral pode ser sorteado arbitrariamente no vazio ou fora da zona de interesse agrônomo. O primeiro passo do SAREL consiste em delimitar o **Frame de Elegibilidade Espacial** através de três filtros geomáticos no Google Earth Engine:

1. **Filtro de Uso da Terra (ESA WorldCover 10m):** São elegíveis exclusivamente as classes agrícolas: *Cropland* (40), *Grassland/Pastagem* (30) e *Solo Exposto/Transição* (60). Florestas nativas primárias (10) e áreas alagadas naturais (90) são descartadas imediatamente.
2. **Filtro de Exclusão de Hidrografia (JRC Global Surface Water):** Aplica-se uma máscara sobre massas d'água permanentes e sazonais com buffer geodésico de segurança de 30 metros (P04), impedindo que margens alagadas ou ilhas fluviais sejam sorteadas.
3. **Filtro de Exclusão Urbana:** Zonas urbanizadas e áreas industriais são removidas com buffer de 150 metros (P04) para afastar interferências antrópicas não agropecuárias.
4. **Janela de Declividade Física (Copernicus DEM):** Recorta-se o intervalo de 3,0% a 20,0% de declividade, correspondente aos relevos suave-ondulados e ondulados onde a mecanização agrícola intensiva potencializa o deflúvio superficial sem a estabilidade dos topos planos nem a florestação compulsória de escarpas muito íngremes (> 45%).

2.2 A Estratificação Multivariada em 18 Estratos Discretos

A amostragem aleatória simples (SRS) é inadequada para fenômenos ambientais, pois tenderia a concentrar amostras nas classes dominantes da paisagem e ignorar os extremos de maior risco. O SAREL adota o **desenho amostral estratificado multivariado** fundamentado na combinação cartesiana de três variáveis biofísicas primárias:

[DEDUÇÃO MATEMÁTICA] Desfazendo o Mal-Entendido: O que Significa a Notação $S \times E \times K\pi$

PONTO CRÍTICO DE PROVA PERICIAL:

O símbolo 'x' na estratificação amostral **NÃO** é uma multiplicação matemática contínua (como na fórmula da RUSLE). Trata-se do **PRODUTO CARTESIANO DE PARTIÇÕES AMOSTRAIS** (tabela de contingência estatística):

3 Classes de Relevo (■) × 3 Classes de Exposição de Solo (Ê) × 2 Níveis de Erodibilidade (K■) = 18 Estratos Discretos

Cada ponto candidato cai em uma única gaveta discreta (ex.: Estrato 2-3-2). Isso garante que o conjunto final de dados represente todas as combinações biofísicas possíveis do território.

As Três Dimensões da Estratificação:

- **Dimensão ■ (Relevo / Declividade):** Dividida em 3 tercis empíricos derivados da distribuição de declividade da área: $S_{\text{■}}$ (*Terço Baixo: relevo suave*), $S_{\text{■}}$ (*Terço Médio: relevo ondulado*) e $S_{\text{■}}$ (*Terço Alto: relevo forte-ondulado*).
- **Dimensão Ê (Exposição Multitemporal de Solo Nu):** Extraída da série histórica decenal de Sentinel-2 L2A. É a fração temporal das observações válidas em que o pixel apresentou NDVI abaixo do limiar crítico (D10). Dividida em 3 tercis: $E_{\text{■}}$ (*Solo raramente descoberto - SPD consolidado*), $E_{\text{■}}$ (*Exposição sazonal típica de safra*) e $E_{\text{■}}$ (*Solo frequentemente exposto e vulnerável*).
- **Dimensão K■ (Erodibilidade Pedológica da Embrapa):** Mapeada em 2 níveis a partir das cartas 1:250.000 da Embrapa Solos (D09): $K_{\text{■}}$ (*Baixa a média erodibilidade: Latossolos e Nitossolos*) e $K_{\text{■}}$ (*Alta a muito alta erodibilidade: Neossolos, Cambissolos e Arenito Caiuá*).

2.3 A Garantia Natural da Classe de Controle (Classe 0)

Um classificador de aprendizado de máquina supervisionado binário (como o XGBoost) falhará se for alimentado apenas com instâncias de erosão ativa (Classe 1). Ele necessita obrigatoriamente de amostras negativas de controle (Classe 0 — áreas estáveis, sem erosão).

No SAREL, a classe negativa não é inventada nem sorteada artificialmente. Ela **emerge organicamente dos estratos de baixa vulnerabilidade** dentro do mesmo frame territorial: amostras sorteadas no Estrato (S■, E■, K■) — terreno suave, solo permanentemente coberto por palhada de plantio direto e solo resistente — configuram os candidatos ideais para a Classe 0. O balanceamento do dataset é garantido pelo próprio desenho experimental.

2.4 A Primeira Lei de Tobler e o Spatial Thinning Geodésico

A Primeira Lei da Geografia de Waldo Tobler (1970) estabelece: *'Todas as coisas estão relacionadas com todas as outras coisas, mas coisas próximas estão mais relacionadas do que coisas distantes'*. Em sensoriamento remoto, pixels contíguos no mesmo talhão compartilham o mesmo relevo, solo e histórico de chuvas. Amostrar pixels vizinhos gera **pseudorrepetição amostral** e inflação ilusória das métricas de acurácia.

Para quebrar a dependência espacial, o SAREL aplica o algoritmo de **Spatial Thinning Geodésico Determinístico**:

- **Distância Mínima Obrigatória ($d_{\min} \geq 1,0$ km - Parâmetro P02):** Nenhum ponto candidato pode ser mantido a menos de 1.000 metros de outro ponto já selecionado.
- **Cálculo Geodésico Haversine:** As distâncias são calculadas na curvatura real da Terra (elipsoide WGS84/GRS80), evitando as distorções métricas de coordenadas planas.
- **Embaralhamento Determinístico de Fisher-Yates:** Para garantir reprodutibilidade pericial absoluta, a ordem de avaliação dos candidatos utiliza semente pseudoaleatória controlada (P07). O mesmo conjunto de entrada gera rigorosamente a mesma malha amostral.

2.5 Amarração Fundiária Auditável (SICAR e SNCR)

Todo centróide aprovado pelo Thinning é submetido imediatamente ao cruzamento espacial com a base local do Cadastro Ambiental Rural (SICAR-PR). O ponto só é promovido se estiver geometricamente contido no polígono de um imóvel rural formalmente cadastrado, resgatando seu Código CAR oficial. Isso garante que nenhuma equipe de campo seja enviada para reservas indígenas, faixas de rodovias ou áreas públicas não autorizadas.

Capítulo 3: Sensoriamento Remoto Multitemporal e Decomposição Harmônica

3.1 A Constelação Sentinel-2 MSI L2A (BOA Harmonized)

A caracterização da resposta espectral do solo e do dossel vegetal no SAREL é realizada através da coleção *COPERNICUS/S2_SR_HARMONIZED* do Google Earth Engine. Utilizam-se imagens Nível 2A com calibração radiométrica de Fundo de Atmosfera (BOA - *Bottom of Atmosphere*), corrigidas para efeitos de aerossóis, vapor d'água e geometria solar pelo algoritmo Sen2Cor. As bandas espectrais selecionadas incluem:

- **B2 (Azul - 490 nm, 10m):** Sensível ao teor de óxidos de ferro e matéria orgânica no horizonte A exposto.
- **B4 (Vermelho - 665 nm, 10m):** Região de forte absorção de clorofila ativa; pico de reflectância de solos vermelhos paranaenses.
- **B8 (Infravermelho Próximo/NIR - 842 nm, 10m):** Altíssima reflectância do mesofilo foliar; contraste máximo com solo nu.
- **B11 e B12 (Infravermelho Médio/SWIR - 1610 e 2190 nm, 20m):** Essenciais para discriminação mineral e teor de umidade do solo.

Os Índices Espectrais Canônicos:

NDVI (Normalized Difference Vegetation Index):

$$\text{NDVI} = (B8 - B4) / (B8 + B4) \quad [\text{Mede vigor e densidade fotossintética, domínio em } [-1, 1]]$$

BSI (Bare Soil Index - Índice de Solo Exposto):

$$\text{BSI} = [(B11 + B4) - (B8 + B2)] / [(B11 + B4) + (B8 + B2)] \quad [\text{Mede exposição mineral direta, domínio em } [-1, 1]]$$

3.2 A Preservação da Máscara de Nuvens SCL (Regra 7 da Lei Fundamental)

A camada Scene Classification Layer (SCL) do Sentinel-2 classifica cada pixel em classes de qualidade (nuvem densa, cirrus, sombra de nuvem, água, vegetação, solo). O SAREL filtra e mascara obrigatoriamente pixels contaminados.

[ERRO METODOLÓGICO CLÁSSICO] A Armadilha da Imputação por Constante no Sensor — Por que é Proibido π

Em versões legadas de pipelines no Earth Engine, desenvolvedores frequentemente aplicavam a função de desmascaramento numérico logo após a filtragem de nuvens para evitar valores nulos. Isso é um **crime científico**: pixels sob nuvens eram substituídos pelo valor 0.0 de NDVI ou BSI, simulando superfícies artificiais que o classificador interpretava como realidade de campo.

A Regra 7 do SAREL determina: Máscara de nuvem existe para remover dados inválidos. A lacuna deve permanecer nula (descarte pelo algoritmo amostral), sem reposição de constantes artificiais.

3.3 O Modelo de Decomposição Harmônica OLS (Zhu & Woodcock 2014)

A variabilidade temporal de um pixel agrícola ao longo dos anos não é aleatória; ela obedece aos ciclos fenológicos das safras (verão e inverno). Para modelar essa dinâmica contínua sem depender de datas isoladas sujeitas a ruídos de cena, o SAREL implementa a **Decomposição Harmônica por Mínimos Quadrados Ordinários (OLS)** para cada banda espectral:

$$y(t) = b_0 + b_1 \cdot t + b_2 \cdot \cos(2\pi t) + b_3 \cdot \sin(2\pi t) + b_4 \cdot \cos(4\pi t) + b_5 \cdot \sin(4\pi t)$$

Onde: t é o tempo em anos decimais; b_0 é o intercepto médio; b_1 é a tendência linear (degradação/recuperação temporal); b_2, b_3 modelam o ciclo anual (365 dias); b_4, b_5 modelam o ciclo semianual (safra/safrinha).

Parâmetros Físicos Derivados do Ajuste:

- **Amplitude Anual:** $A_{\text{anual}} = \sqrt{(b_{\text{max}}^2 + b_{\text{min}}^2)}$ • Mede o contraste entre a máxima biomassa e o pós-colheita.
- **Fase Anual:** $\phi_{\text{anual}} = \text{atan2}(b_{\text{max}}, b_{\text{min}})$ • Indica a época do ano em que ocorre o pico de reflectância.
- **Qualidade do Ajuste (R^2 e Erro-Padrão):** Todo coeficiente harmônico exportado carrega suas métricas de ajuste estatístico. Séries com número insuficiente de cenas recebem o status 'indisponível (insuficiente)' (D11).

3.4 O Erro Sistemático da Projeção Web Mercator na Declividade

A declividade do terreno é um dos principais motores do carreamento hídrico. A auditoria do sistema revelou que softwares legados calculavam o relevo sobre a projeção *Web Mercator* (EPSG:3857). No Paraná (latitudes -22° a -26° S), o fator de distorção de escala horizontal do Web Mercator é da ordem de 1,10. Como a declividade divide o desnível vertical pela distância horizontal, **a declividade no Paraná era subestimada em aproximadamente 10% de forma sistemática em todas as amostras.**

O SAREL corrigiu essa distorção em definitivo: todo o processamento topográfico do DEM Copernicus GLO-30 é executado na projeção métrica oficial **SIRGAS 2000 / UTM 22S (EPSG:31982)** a 30 metros, com guarda física que rejeita valores fora do intervalo plausível de [0°, 75°].

Capítulo 4: A Linha de Base RUSLE e a Governança Metodológica

4.1 A Linha de Base RUSLE como Padrão Comparativo

A Equação Universal de Perda de Solo Revisada (RUSLE - *Revised Universal Soil Loss Equation*; Renard et al., 1997) é o modelo empírico-paramétrico mais consagrado mundialmente para estimativa de erosão hídrica em bacias hidrográficas:

$$A = R \times K \times LS \times C \times P \quad [\text{Perda Média Anual de Solo em t / (ha} \cdot \text{ano)}]$$

O PAPEL EPISTEMOLÓGICO DA RUSLE NO SAREL: Ela existe para servir de **linha de base de comparação (benchmark)**. O objetivo do mestrado é responder se o modelo supervisionado de inteligência artificial (XGBoost) supera a acurácia da equação clássica. Por esse motivo, **a RUSLE nunca pode ser usada para gerar rótulos** (Regra 4).

4.2 O Fator C Regional de Durigon et al. (2014) [Decisão D01]

O Fator C representa a razão entre a perda de solo sob uma dada cobertura vegetal e manejo e a perda sob solo continuamente descoberto e mantido em preparo convencional. A literatura clássica (Wischmeier & Smith, 1978) utilizava tabelas estáticas anuais, inadequadas para a rotação de culturas safra/safrinha no Brasil.

O SAREL adota a equação regional concebida por **Durigon et al. (2014)** para monitoramento multitemporal em bacias hidrográficas tropicais:

$$C = (1 - NDVI) / 2$$

Propriedades Físico-Matemáticas da Equação:

- Quando o solo está completamente nu ou exposto ($NDVI \approx 0,0$), o Fator C resulta em 0,50 (alta suscetibilidade).
- Sob dossel denso e vigoroso ($NDVI \approx 0,90$), o Fator C cai para 0,05 (altíssima proteção mecânica contra o impacto da chuva).
- A função é estritamente delimitada: para NDVI contido em $[-1, 1]$, o valor de C pertence exatamente a $[0, 1]$ sem necessitar de truncamentos ou cortes artificiais.

4.3 O Fator P Tabelado (Práticas Conservacionistas Mecânicas)

O Fator P expressa a eficácia de estruturas artificiais de suporte mecânico (como terraceamento em nível, terraceamento em gradiente e cultivo em contorno) na redução do volume e velocidade da enxurrada. Quando as práticas da fazenda são desconhecidas na escala orbital, o SAREL atribui o valor **1,0** (conforme Renard et al., 1997), carimbando compulsoriamente a proveniência como 'tabelado' (Regra 3), impedindo que seja confundido com uma medição de campo.

4.4 As Decisões Pendentes (D13, D14, D15) e o Invariante 1

A equação universal $A = R \cdot K \cdot LS \cdot C \cdot P$ depende simultaneamente dos cinco fatores. No estado atual da pesquisa:

- **D13 (Fator R - Erosividade Pluviométrica):** Aguarda definição pelo pesquisador entre formulações de energia cinética (Brown & Foster 1987) e coeficientes regionais de chuvas do Paraná (Waltrick et al., 2015).
- **D14 (Fator K - Erodibilidade Numérica):** A Embrapa fornece a classe categórica. Converter classe em número em MJ·mm/ha·h·ano exige seleção documental formalmente embasada.
- **D15 (Fator LS - Comprimento e Gradiente de Rampa):** Requer escolha entre equações de Moore & Burch (1986) ou Desmet & Govers (1996).

O Invariante 1 do SAREL determina com rigor absoluto: Enquanto D13, D14 e D15 estiverem pendentes, o campo *Perda de Solo* permanece como indisponível (causa: decisao-pendente). O sistema recusa terminantemente qualquer multiplicador ad-hoc ou fórmula inventada.

Capítulo 5: Inteligência Fundiária, Desempenho R*Tree e Conformidade LGPD

5.1 O Arcabouço Cadastral Brasileiro e o Estado do Parana

A degradação do solo por erosão hídrica é um fenômeno estritamente físico que ocorre de acordo com as leis do relevo, gravidade e escoamento superficial. Contudo, a conservação do solo, as práticas de manejo, a fiscalização ambiental e os incentivos financeiros (como crédito rural verde e pagamentos por serviços ambientais) ocorrem dentro de **limites jurídicos de propriedade**. Sem o cruzamento cadastral, um mapa de erosão é uma abstração acadêmica desprovida de eficácia operacional.

O SAREL integra os três maiores cadastros públicos do território paranaense:

SICAR-PR (Sistema de Cadastro Ambiental Rural): ~560.000 propriedades rurais cadastradas no Paraná, contendo delimitação de Área de Preservação Permanente (APP), Reserva Legal (RL) e Remanescente de Vegetação Nativa.

SIGEF / INCRA (Sistema de Gestão Fundiária): ~170.000 parcelas georreferenciadas com precisão posicional submétrica e trânsito em julgado registral.

SNCR (Sistema Nacional de Cadastro Rural): ~957.000 registros fundiários do INCRA para validação de estrutura agrária e módulos fiscais.

5.2 O Gargalo Computacional e a Solução Espacial R*Tree

O cruzamento de dezenas de milhares de pontos amostrais com uma base vetorial de 560 mil polígonos complexos (muitos com milhares de vértices) através de uma varredura sequencial direta (*brute force*) possui complexidade temporal $O(N \times M)$. Em termos práticos, uma única consulta de ponto levaria de 12 a 45 segundos, inviabilizando um sistema interativo.

O SAREL soluciona este gargalo através da estruturação da malha fundiária em uma árvore de indexação espacial multidimensional **R*Tree** (Beckmann et al., 1990), particionando o espaço em caixas envoltórias mínimas (*Minimum Bounding Boxes - MBR*):

- 1. Filtragem Hierárquica em Tempo Logarítmico:** A busca pelo polígono que contém o ponto reduz-se a $O(\log N)$. A árvore elimina instantaneamente 99,99% do estado do Paraná que não intersecta o MBR do ponto.
- 2. Teste Exato Ponto-em-Polígono (Point-in-Polygon):** O teste trigonométrico do raio (*Ray Casting Algorithm*) só é disparado para os escassos 1 a 3 polígonos cujas MBRs sobrepoem o ponto investigado.
- 3. Desempenho em Produção:** Tempo médio de resposta espacial estritamente **inferior a 5 milissegundos (< 5 ms)** por consulta em hardware convencional, permitindo consultas instantâneas no mapa interativo.

[DEDUÇÃO MATEMÁTICA] Complexidade Algorítmica da Indexação Espacial R*Tree

Em busca exaustiva linear: $T(N) = O(N)$, para $N = 560.000$ polígonos.

Com R*Tree particionada: $T(N) = O(\log_{\{M\}} N) + O(K \times V_{\{pol\}})$, onde M é a capacidade dos nós, K é o número de candidatos (≤ 3) e $V_{\{pol\}}$ são os vértices locais.

Redução de latência medida: de ~18.500 ms para **3,4 ms** por ponto amostrado.

5.3 A Conformidade Rigorosa com a LGPD (Lei no 13.709/2018)

A utilização de dados cadastrais impõe um dever de conformidade irrestrito com a Lei Geral de Proteção de Dados Pessoais. Nomes de proprietários, CPFs, contratos de arrendamento e dados fiscais são estritamente protegidos pelo sigilo legal e pela ética científica.

O SAREL adota o princípio de **Segurança e Privacidade desde a Concepção (Privacy by Design)** através de uma arquitetura de isolamento hermetico:

- 1. Camada localOnly.ts:** Todos os dados pessoais sensíveis residem exclusivamente no armazenamento local da máquina do analista ou servidor institucional seguro. Nenhuma informação pessoal é concatenada aos payloads enviados a APIs externas ou modelos de inferência.

2. **Anonimização Geométrica Pura:** O pipeline do XGBoost consome unicamente o identificador numérico interno da feição (UUID) e sua geometria vetorial. O modelo desconhece quem é o proprietário da terra.
3. **Zero Vazamento de PII (Personally Identifiable Information):** Auditorias de rede confirmam que nenhum campo com CPF, telefone ou nome transita na camada de inteligência geoespacial.

[ATENÇÃO PARA A BANCA] Posicionamento para a Banca: Propriedade Privada como Unidade de Acao

Se a banca indagar: *'Por que não trabalhar apenas com a bacia hidrográfica ou com pixels contínuos?'*

Sua Resposta: 'A bacia hidrográfica é a unidade biofísica do ciclo hidrológico, mas a propriedade rural é a unidade soberana de tomada de decisão, atuação fiscal e manejo conservacionista. A erosão em um pixel de montante de uma fazenda afeta o vizinho de jusante. Integrar o CAR permite ao poder público e aos comitês de bacia cobrar quem gera o sedimento e recompensar quem conserva o solo.'

Capítulo 6: Campanha de Rotulagem Cega e Estatística de Concordância

6.1 O Protocolo de Rotulagem em Duplo-Cego: Mitigando o Vies de Confirmacao

O maior risco metodologico em sensoriamento remoto aplicado a erosao e a contaminacao subjetiva do anotador (vies de confirmacao: o pesquisador tende a classificar como 'erodido' um ponto que ele ja sabe estar em alta declividade). Para blindar a integridade da pesquisa de mestrado, o SAREL formaliza um protocolo de quatro fases:

- Fase A (Calibracao e Chaves de Interpretacao):** Sessao previa conjunta entre os interpretes com 30 pontos de referencia historica para alinhar padroes de textura, reflectancia do solo exposto e cicatrizes de enxurrada.
- Fase B (Rotulagem Independente em Duplo-Cego):** O Avaliador 1 e o Avaliador 2 recebem a mesma lista de 150 coordenadas espaciais, porem embaralhadas em ordens distintas e totalmente desprovidas de dados cadastrais, topograficos ou de satellite pre-anotados. Cada interprete classifica cada ponto de forma 100% autonoma nas classes: **0 (Sem Erosao Aparente)**, **1 (Erosao Laminar Incipiente)** ou **2 (Erosao Laminar Severa / Sulcos)**.
- Fase C (Auditoria Estatistica de Concordancia):** Calculo do Coeficiente Kappa de Cohen (κ) entre os dois avaliadores.
- Fase D (Arbitragem de Divergencias por Terceiro Especialista):** Apenas os pontos onde Avaliador 1 $\neq$ Avaliador 2 sao submetidos a um terceiro pesquisador senior independente, que resolve o rotulo definitivo com base em ortofoto de altissima resolucao.

6.2 A Formulacao Matematica do Coeficiente Kappa de Cohen (κ)

A simples porcentagem de concordancia bruta (Acuracia Observada, $P_{\{obs\}}$) e matematicamente enganosa porque ignora a concordancia que ocorreria puramente ao acaso. O Coeficiente Kappa de Cohen (Cohen, 1960) desconta a probabilidade do acaso:

[DEDUÇÃO MATEMÁTICA] Equacao do Coeficiente Kappa de Cohen (κ)

$$\kappa = (P_{\{obs\}} - P_{\{esp\}}) / (1 - P_{\{esp\}})$$

Onde:

$P_{\{obs\}} = \sum f_{\{ii\}} / N$ e a proporcao observada de concordancia exata (diagonal principal da matriz de confusao).
 $P_{\{esp\}} = \sum (r_{\{i\}} \times c_{\{i\}}) / N^2$ e a proporcao de concordancia esperada unicamente pela distribuicao marginal das probabilidades das linhas ($r_{\{i\}}$) e colunas ($c_{\{i\}}$).

Interpretacao Canonica segundo Landis & Koch (1977):

Faixa de Kappa (κ):	Qualidade da Concordancia	Impacto no Pipeline SAREL
< 0,00	Desacordo Sistemtico	Invalidacao imediata do lote de rotulagem
0,00 a 0,20	Concordancia Insignificante	Invalidacao imediata do lote de rotulagem
0,21 a 0,40	Concordancia Razoavel	Invalidacao do lote; revisao das chaves visuais
0,41 a 0,60	Concordancia Moderada	Alerta metodologico; trava de exportacao acionada
0,61 a 0,80	Concordancia Substancial	Aprovado para calibracao com ressalvas
0,81 a 1,00	Concordancia Quase Perfeita	Aprovacao plena para treinamento do XGBoost

[ERRO METODOLÓGICO CLÁSSICO] A Regra de Ouro do SAREL: Trava em $\kappa < 0,60$

Se após a rotulagem das duas rodadas cegas o índice Kappa calculado for menor que 0,60, o sistema **bloqueia compulsoriamente** a exportação do dataset para o modelo de Machine Learning. Isso impede que ruído humano seja incorporado aos pesos do XGBoost, garantindo idoneidade acadêmica absoluta.

6.3 Protocolo de Campo com KoboToolbox Offline e Evidências Físicas

Para os pontos amostrados no campo físico, utiliza-se o aplicativo **KoboToolbox** instalado em dispositivos móveis com GPS GNSS submétrico e armazenamento 100% offline (dispensando conectividade celular no interior das fazendas). O técnico de campo é treinado para registrar as seguintes evidências biofísicas inequívocas:

- 1. Pedestais de Erosão:** Colunas milimétricas ou centimétricas de solo que foram protegidas do impacto direto das gotas de chuva por fragmentos de rocha (seixos) ou matéria vegetal remanescente, enquanto o solo circundante foi decapado pela erosão laminar.
- 2. Exposição Radicular:** Raízes de culturas anuais ou gramíneas projetadas acima da superfície do terreno, denunciando a perda da camada arável superficial nos últimos ciclos fenológicos.
- 3. Pavimento Residual de Seixos:** Concentração anormal de cascalhos e partículas grossas na superfície devido ao arraste seletivo da fração argilosa e silte pela enxurrada laminar superficial.
- 4. Deposição em Patamares e Cercas:** Acúmulo de leques coluviais de sedimento fino retidos a montante de terraços, estradas rurais ou cercas limitrofes.

6.4 O Conjunto de Teste Independente com Drone VANT (Held-Out Test Set)

Para validar o modelo de forma incontestável na qualificação do mestrado, um subconjunto independente de propriedades rurais é aerolevanteado com Veículo Aéreo Não Tripulado (VANT / Drone), produzindo ortomosaicos RGB de altíssima resolução com *Ground Sampling Distance (GSD) inferior a 3 cm/pixel*. Neste nível de detalhe, até mesmo os microsulcos de erosão são visualmente inequívocos.

Este conjunto com drone permanece como **conjunto de teste completamente isolado (held-out)**: ele nunca é visto pelo XGBoost durante o treinamento nem durante as rodadas de validação cruzada LOCO. Ele constitui o árbitro final e independente da capacidade de generalização do SAREL.

Capítulo 7: Modelagem Preditiva XGBoost e Explicabilidade SHAP

7.1 Por que Gradient Tree Boosting (XGBoost)

A modelagem preditiva da erosão laminar no SAREL emprega o algoritmo **XGBoost (Extreme Gradient Boosting)** (Chen & Guestrin, 2016). A escolha deste algoritmo em detrimento de modelos lineares ou redes neurais profundas fundamenta-se nas peculiaridades matemáticas dos dados ambientais:

- 1. Natureza Tabular Mista dos Preditores:** O vetor de atributos combina variáveis contínuas (NDVI médio, amplitude bi-harmônica, declividade em graus, curvatura do terreno) com variáveis categóricas (classes pedológicas da Embrapa, geologia regional) e dados ordinais. Árvores de decisão baseadas em gradiente lidam naturalmente com escalas heterogêneas sem exigir transformações arbitrárias de normalização.
- 2. Captura de Interações Não-Lineares Complexas:** A erosão é um fenômeno de limiares (ex.: um solo arenoso tolera baixa declividade, mas entra em colapso repentino acima de 8% de inclinação quando desprovido de palhada). O XGBoost particiona o espaço hiperdimensional em hiper-retângulos ortogonais, capturando interações de alta ordem.
- 3. Controle Estrito de Sobreajuste (Overfitting):** Ao contrário de Random Forests convencionais, o XGBoost incorpora termos de regularização L1 (Lasso) e L2 (Ridge) diretamente na função de perda objetivo, penalizando árvores excessivamente profundas ou pesos de folha discrepantes.

7.2 O Mecanismo da Validação Cruzada Espacial LOCO (K=5)

Na modelagem estatística tradicional de Machine Learning, a separação entre treino e teste é feita por amostragem aleatória simples (*Random K-Fold*). Em dados geoespaciais, esse procedimento é **fatalmente incorreto** devido à Primeira Lei da Geografia de Waldo Tobler (autocorrelação espacial): se um ponto de teste estiver localizado a 500 metros de um ponto de treino na mesma fazenda ou na mesma topossequência de solo, o modelo irá 'decorar' o contexto local em vez de aprender a física da erosão, gerando acurácias ilusórias de 98% a 100%.

O SAREL implementa a **Validação Cruzada Espacial por Deixar um Cluster de Fora (Leave-One-Cluster-Out - LOCO)** com K=5 partições geográficas, baseadas nas grandes bacias hidrográficas do Estado do Paraná:

- Cluster 1 (Bacia do Rio Paranapanema):** Região Norte e Noroeste, dominada por Latossolos Vermelhos e textura arenosa sobre formações sedimentares (Arenito Caiua).
- Cluster 2 (Bacia do Paraná III):** Região Oeste, solos de altíssima fertilidade natural derivados de derrames basálticos (Latossolos e Nitossolos Eutroférricos - 'Terra Roxa').
- Cluster 3 (Bacia do Rio Ivaí):** Faixa Central e Noroeste, zona de transição geomorfológica com relevo ondulado a forte-ondulado.
- Cluster 4 (Bacia do Rio Piquiri):** Região Centro-Oeste, com agricultura intensiva e áreas de pastagem em relevo suave.
- Cluster 5 (Bacia do Rio Iguaçu):** Planaltos frios do Sul e Centro-Sul do Paraná, com presença expressiva de Cambissolos e relevo acidentado.

Protocolo de Avaliação Espacial: O modelo é treinado sobre quatro macrobacias e testado exclusivamente na quinta macrobacia que ele *nunca viu*. Esse ciclo é repetido cinco vezes. Apenas a média das cinco iterações constitui a estimativa válida da capacidade de generalização do SAREL no Estado do Paraná.

[ERRO METODOLÓGICO CLÁSSICO] O 'Elefante na Sala': A Acuracia de 100% no XGBoost de Teste

Durante os primeiros testes do pipeline com scripts preliminares ou dados sintéticos, o modelo atingiu **100% de acuracia**. Este resultado decorre exclusivamente do uso de bases geradas por regras determinísticas simples.

Posicao Cientifica Oficial: Em dados reais de campo e sensoriamento remoto multitemporal, a acuracia fisica esperada situa-se na faixa entre **84% e 93%**. Qualquer alegacao de acuracia superior a 95% em erosao regional e indicio cabal de vazamento de dados (*data leakage*) ou dependencia espacial nao controlada. A banca examinadora do mestrado espera maturidade critica para discutir os limites do modelo.

7.3 Explicabilidade com SHAP (SHapley Additive exPlanations)

Modelos de Machine Learning complexos sao historicamente criticados por funcionarem como 'caixas-pretas'. No SAREL, a explicabilidade de cada predicao individual e obtida atraves da **Teoria dos Jogos Cooperativos de Lloyd Shapley** (Nobel de Economia de 2012), implementada pelo algoritmo **TreeSHAP** (Lundberg et al., 2020).

[DEDUÇÃO MATEMÁTICA] Equacao dos Valores SHAP ($\phi_{\{i\}}$)

$$\phi_{\{i\}} = \sum_{S \subseteq F \setminus \{i\}} [|S|! (|F| - |S| - 1)! / |F|!] \times [f_{\{x\}}(S \cup \{i\}) - f_{\{x\}}(S)]$$

Onde $|F|$ e o total de preditores ambientais, S e um subconjunto qualquer de variaveis, e $[f_{\{x\}}(S \cup \{i\}) - f_{\{x\}}(S)]$ representa a contribuicao marginal da variavel i na predicao da feicao x .

O grafico **SHAP Beeswarm** gerado pelo SAREL sintetiza a contribuicao fisica de cada variavel:

- Cada ponto representa uma propriedade rural analisada.
- A cor indica o valor da variavel (vermelho = alto, azul = baixo).
- A posicao no eixo horizontal indica se aquela variavel aumentou (para a direita) ou diminuiu (para a esquerda) a probabilidade de ocorrencia de erosao severa.

Por exemplo: valores azuis de NDVI medio acumulados no lado positivo do eixo X revelam visualmente que baixa cobertura vegetal aumenta diretamente o risco de degradacao do solo.

Capítulo 8: A Lei Fundamental do SAREL e os 7 Invariantes de Exportação

8.1 A Lei Fundamental do Sistema

[ATENÇÃO PARA A BANCA] A LEI FUNDAMENTAL DO SAREL (Regra de Ouro)

'Nenhum parametro inventado. Nenhuma formula sem citacao de literatura formal. Nenhum dado simulado sem carimbo compulsorio de proveniencia.'

O SAREL prefere reportar 'indisponivel (causa: decisao-pendente)' a gerar um numero matematicamente esteticocromatico porem cientificamente falso.

8.2 Os 7 Invariantes de Integridade em Runtime

Para garantir que nenhuma versao do sistema, script auxiliar ou refatoracao fira a integridade cientifica, o SAREL implementa **7 Invariantes de Validacao** que sao verificados compulsoriamente antes de qualquer exportacao de dados:

No	Invariante	Descricao Operacional e Regra de Bloqueio
1	Perda de Solo Bloqueada	Enquanto D13, D14 e D15 estiverem pendentes, o campo Perda de Solo da USLE permanece como indisponivel.
2	Fator P Tabelado	O Fator P adota 1.0 (Renard et al., 1997) e e carimbado compulsoriamente como 'tabelado' nos metadados.
3	Concordancia de Rotulagem	O Coeficiente Kappa (κ) inter-observadores deve ser ≥ 0,60. Se inferior, a exportacao e abortada.
4	LOCO Espacial	A validacao cruzada deve utilizar clusters geograficos sem sobreposicao de coordenadas ou buffers espaciais.
5	Projecao Cartografica Conforme	Calculos de declividade e relevo devem ocorrer em UTM Fuso 22S (EPSG:31982). Proibido Web Mercator.
6	Dominio Analitico de C	O Fator C de Durigon (2014) deve resultar estritamente em [0, 1] para qualquer NDVI contido em [-1, 1].
7	Detector de Constante Disfarçada	Se qualquer coluna continua de entrada apresentar variancia nula (σ < 10^{-6}) ou valor unico em mais de 99,99% dos registros, a exportacao e abortada.

Capítulo 9: Roteiro de Estudos, Glossário Técnico e Preparação para a Banca

9.1 As Cinco Perguntas Classicas da Banca Examinadora do Mestrado

Pergunta 1: 'Por que voce utilizou a expressao $S^{\wedge} \times E^{\wedge} \times K^{\wedge}$ se a USLE usa a multiplicacao $A = R \times K \times LS \times C \times P^{\pi}$ '

Sua Defesa: 'A banca esta corretissima em relaçao a USLE: na equacao de perda de solo, os fatores sao multiplicativos. Porem, no Capitulo de Metodologia Amostral, o simbolo $\times$ nao representa multiplicacao aritmetica, e sim o **Produto Cartesiano da Estatistica de Amostragem Estratificada**. O acento circunflexo denota as categorias discretizadas de Declividade (3 classes), Cobertura Vegetal (3 classes) e Solo (2 classes), totalizando 18 estratos amostrais mutuamente exclusivos. Trata-se de teoria amostral de Cochran (1977), e nao da formula de Wischmeier.'

Pergunta 2: 'Como voce garante que o modelo nao decorou os dados vizinhos π '

Sua Defesa: 'Adotamos duas barreiras matematicas contra o vazamento de dados espaciais: primeiro, o *Thinning Geodesico* com raio minimo de 1,0 km elimina a autocorrelacao local imediata; segundo, a validacao e feita por *Leave-One-Cluster-Out (LOCO)* particionado nas 5 grandes bacias do Parana. O modelo e avaliado em bacias completamente ineditas.'

Pergunta 3: 'Por que nao rodar um Random K-Fold comum com 10 folds π '

Sua Defesa: 'O K-Fold aleatorio convencional viola o pressuposto basico de independencia das observacoes (i.i.d.) em dados espaciais devido a Lei de Tobler. Ele produz acuracias infladas artificialmente e fracassa quando aplicado em novas propriedades rurais.'

Pergunta 4: 'A acuracia inicial de 100% que apareceu nos testes preliminares e confiavel π '

Sua Defesa: 'Nao, de forma alguma. Tivemos a integridade cientifica de identificar que aquela acuracia era um artefato decorrente de dados sinteticos gerados por regras deterministas. Na aplicacao real de campo e satellite com 150 pontos rotulados em duplo-cego, a faixa fisica esperada situa-se entre 84% e 93%.'

Pergunta 5: 'Como a LGPD e atendida se o sistema cruza dados com o CAR e SIGEF π '

Sua Defesa: 'O SAREL opera sob o principio de Privacy by Design com o modulo localOnly.ts. O modelo preditivo XGBoost consome exclusivamente o identificador anonimo da feicao e sua geometria vetorial. Nenhum dado pessoal (CPF, nome, telefone) e trafegado para o pipeline preditivo ou APIs externas.'

9.2 Glossario Tecnico Essencial para Memorizacao

- **BOA Harmonized:** Reflectancia de Fundo de Atmosfera (*Bottom of Atmosphere*) corrigida para efeitos atmosfericos, normalizada entre sensores Sentinel-2A e 2B.
- **Thinning Geodesico:** Algoritmo de filtragem espacial que remove amostras proximas demais, garantindo espacamento minimo $\geq d_{\min}$ sob a metrica geodinamica de WGS-84.
- **R*Tree:** Estrutura de dados em arvore que indexa retangulos envolventes minimos (MBR), acelerando buscas espaciais de $O(N)$ para $O(\log N)$.
- **Kappa de Cohen (κ):** Metrica estatistica que quantifica a concordancia real entre observadores independentes alem do acaso fortuito.

- **TreeSHAP:** Algoritmo exato de tempo polinomial para calcular valores Shapley em modelos baseados em árvores de decisão.
- **Held-Out Test Set:** Conjunto de dados de teste estritamente isolado que nunca participa de qualquer etapa de seleção de hiperparâmetros ou treino.

[CONCEITO FUNDAMENTAL] Mensagem Final para a Pesquisa de Mestrado

Este compendio reúne toda a solidez matemática, física e computacional do SAREL v2.0. Estude cada equação, compreenda os porquês de cada decisão e apresente sua dissertação com a certeza de quem construiu uma ferramenta de vanguarda para a conservação do solo no Estado do Paraná.