UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ (UTFPR) — CÂMPUS MEDIANEIRA
PROGRAMA DE PÓS-GRADUAÇÃO EM TECNOLOGIAS COMPUTACIONAIS PARA O AGRONEGÓCIO (PPGTCA)

FUNDAMENTAÇÃO CIENTÍFICA E DEFESA METODOLÓGICA

Replicabilidade em Inteligência Artificial e Controle Estrutural de Viés no Uso de Sensores Aerotransportados (VANT): Subsídios Epistemológicos, Evidências da Literatura e Roteiro de Arguição para a Dissertação de Mestrado

Mestrando: Luis Alfredo Ferreira da Silva
Orientador: Prof. Dr. Claudio Leones Bazzi
Linha de Pesquisa: Geotecnologias Aplicadas e Modelagem Computacional no Agronegócio
Projeto: SAREL v2.0 (Validação e Predição de Erosão Laminar)
Recorte Territorial: Bacia Hidrográfica do Rio Paraná III (BP3)
Finalidade: Suporte à Qualificação e Defesa de Dissertação

1. Introdução e Contexto Epistemológico da Arguição

Durante apresentações em seminários acadêmicos e bancas examinadoras na área de Geociências, Agronomia e Engenharia Agrícola, é recorrente o surgimento de duas indagações centrais direcionadas ao uso de Inteligência Artificial (IA) e veículos aéreos não tripulados (VANTs) no mapeamento de perdas de solo por erosão laminar:

Pergunta 1 (Natureza das IAs): ***'Como tornar o trabalho replicável, uma vez que as IAs são probabilísticas?'***

Pergunta 2 (Sensores de Alta Resolução): ***'Corre-se o risco do treinamento "VICIAR" o sistema em dados tão precisos quanto os que iremos obter com o Spectro (VANT)?'***

Essas questões expressam preocupações legítimas de pesquisadores habituados a modelos matemáticos analíticos fechados (como a USLE e RUSLE; WISCHMEIER; SMITH, 1978; RENARD et al., 1997). No entanto, ambas encerram premissas conceituais que precisam ser desfeitas e enquadradas sob as diretrizes de reprodutibilidade computacional internacional em IA (PINEAU et al., 2021) e sensoriamento remoto multiescala (ALVAREZ-VANHARD et al., 2021; WOODCOCK; STRAHLER, 1987). Este documento sistematiza a fundamentação teórica, as equações estatísticas e o lastro científico arquivado na base local do projeto, demonstrando que o Sistema de Amostragem e Rotulagem para Erosão Laminar (SAREL) foi concebido exatamente para neutralizar esses riscos.

2. Eixo I: A Replicabilidade Científica Diante da Natureza Probabilística das IAs

A premissa da primeira pergunta confunde três conceitos epistemológicos distintos: **(i) modelagem probabilística**, **(ii) estocasticidade algorítmica** e **(iii) irreprodutibilidade computacional**. Um sistema computacional probabilístico não é equivalente a um sistema caótico, arbitrário ou irreprodutível. Na ciência da computação contemporânea, a replicabilidade em modelos de aprendizado de máquina é sustentada por três pilares inegociáveis:

2.1 Pilar 1: Determinismo Numérico e Reprodutibilidade Computacional Estrita

Os algoritmos de aprendizado supervisionado utilizados em sensoriamento remoto (como *Gradient Boosted Decision Trees* / XGBoost, *Random Forests* ou Regressões Regularizadas Lasso/ElasticNet; CHEN; GUESTRIN, 2016) operam estritamente sobre **Geradores de Números Pseudoaleatórios (PRNG)**. Toda a aleatoriedade aparente (sorteio de amostras, seleção de variáveis por split ou particionamento de dobras) é uma função matemática determinística a partir de uma semente (*seed*).

Conforme estabelecido pelo programa de reprodutibilidade da *NeurIPS* (PINEAU et al., 2021), a reprodutibilidade de código é assegurada no SAREL por:

• **Fixação Universal de Sementes:** Todos os geradores de números aleatórios (`random_state`) são pré-fixados e declarados no pacote de reprodutibilidade científica (Decisões D24 e D25).

• **Congelamento de Ambiente e Dependências:** Versões de bibliotecas numéricas e compiladores são fixadas via arquivos de trava (`package-lock.json`, contêineres e hashes SHA-256), impedindo variações de ponto flutuante entre ambientes.

• **Persistência de Artefatos Treinados:** O produto final da pesquisa inclui os pesos e estruturas de decisão do modelo serializados em disco (formato JSON/ONNX), permitindo que qualquer avaliador replique exatamente a mesma inferência sobre dados novos sem precisar retreinar o algoritmo.

2.2 Pilar 2: Reprodutibilidade Estatística e Invariância à Semente (Anti-Seed Hacking)

A exigência científica fundamental não é apenas que 'o código rode com o mesmo resultado fixando uma semente específica' (o que caracterizaria *seed hacking*, isto é, a escolha oportunista de uma semente favorável). A questão crucial é: **a hipótese científica se sustenta independente da estocasticidade da amostragem?**

Em sensoriamento remoto ambiental, o recente estudo publicado na **Nature Communications por Ploton et al. (2020)** demonstrou que a validação aleatória convencional (*random k-fold*) produz acurácias ilusórias e espúrias devido à autocorrelação espacial entre amostras próximas. Quando submetidos à validação espacial rigorosa, modelos sem lastro biofísico colapsam. Para garantir robustez estatística genuína, o SAREL adota:

• **Validação Cruzada Espacial em Blocos (Spatial Block Cross-Validation):** O espaço é particionado em blocos independentes baseados no alcance do variograma empírico (a ≈ 50 m; ROBERTS et al., 2017), eliminando o vazamento de dependência espacial (Primeira Lei de Tobler).

• **Inferência por Bootstrap Agrupado em Nível de Polígono (Decisão D25):** O desempenho preditivo e a comparação pareada com a RUSLE são calculados via 1.000 iterações de *bootstrap* reamostradas na unidade de agrupamento dos 36 polígonos independentes (CAMERON; GELBACH; MILLER, 2008).

• **Reporte Mandatório de Intervalos de Confiança (IC 95%):** O critério de confirmação da hipótese exige que o limite inferior do IC 95% do ganho (Delta rho = rho_XGBoost - rho_RUSLE) seja estritamente superior a 0,10, provando que o ganho é estrutural e não estocástico.

2.3 Pilar 3: Ciência Aberta, Prevenção de Data Leakage e Pré-Registro Metodológico

Como documentado por **Kapoor e Narayanan (2023, Cell Press / Patterns)** em uma revisão abrangendo 17 campos científicos, o vazamento de dados (*data leakage*) é a causa primária da crise de reprodutibilidade em ciência guiada por aprendizado de máquina. O SAREL blinda o processo científico operando sob as **9 Regras Invioláveis da Lei Fundamental** e os **7 Invariantes de Integridade**. Seguindo o movimento de pré-registro científico (NOSEK et al., 2018), os 18 estratos biofísicos (D12), as regras de segregação cega e os critérios de refutação (D25) foram registrados formalmente no repositório antes do processamento dos dados de voo, tornando impossível o *p-hacking* ou a formulação de hipóteses a posteriori (*HARKing*).

Dessa forma, o projeto estabelece uma linha clara entre variabilidade estocástica inevitável do treinamento e a invariância da conclusão científica, garantindo que qualquer pesquisador independente chegue às mesmas inferências sobre a Bacia do Paraná III.

3. Eixo II: O Risco de 'Viciar' o Sistema com Dados do VANT (Sensor Spectral 2)

A segunda pergunta indaga se o treinamento do sistema corre o risco de ser 'viciado' (sobreajustado ou enviesado) pela altíssima resolução dos dados obtidos pelo drone multiespectral (VANT Spectral 2, Nuvem UAV, 5 bandas calibradas: Azul, Verde, Vermelho, RedEdge e NIR, com GSD de 3,59 a 3,96 cm e acurácia posicional CE90 de 1,47 m).

A resposta científica é direta: Esse vício existiria se o projeto cometesse o erro metodológico clássico de misturar suportes espaciais. No SAREL, esse risco é formalmente eliminado por uma decisão arquitetural fundamental: **o dado de VANT NÃO é preditor (feature de entrada) do modelo preditivo; ele é estritamente o instrumento de rotulagem (ground truth).**

3.1 O Problema da Incompatibilidade de Suporte Espacial e o Fator de Escala

O receio da banca reflete o problema clássico de escala teorizado por **Woodcock e Strahler (1987)** no *Remote Sensing of Environment*: quando o elemento físico observado (ex.: microssulco de erosão de 20 cm) é maior que o pixel (GSD de 4 cm do VANT), ele opera em *Resolução-H* (feição discreta diretamente detectável); quando projetado na célula de 10 m do satélite Sentinel-2, ele opera em *Resolução-L* (mistura espectral sub-pixel onde cada célula integra a radiança de 62.500 micropixels de VANT). Tentar alimentar um modelo com texturas de 4 cm para prever em satélite geraria o clássico *Modifiable Areal Unit Problem* (MAUP; OPENSHAW, 1984) e falha preditiva total.

3.2 A Sinergia VANT-Satélite no SAREL: O Drone como Calibrador (Decisões D06 e D26)

Em sua revisão sistemática sobre sinergias entre VANT e satélites, **Alvarez-Vanhard, Corpetti e Houet (2021)** classificam o acoplamento metodológico ideal em quatro estratégias, destacando a **Calibração de Modelos (*Model Calibration*)**: o VANT não substitui os dados orbitais, mas fornece o gabarito pericial de alta precisão necessário para calibrar o satélite.

• **Vetor de Preditores Orbitais (Entrada X):** O modelo consome exclusivamente variáveis contínuas em escala de bacia: Sentinel-2 MSI Nível-2A a 10 m/20 m, Copernicus DEM GLO-30 a 30 m (D21), pedologia oficial Embrapa Solos (D14) e climatologia CHIRPS (D13). O modelo nunca consome os micropixels do drone como entrada.

• **Alvo Contínuo e Não-Binarizado (Saída Y):** Como alertam **Altman e Royston (2006, BMJ)**, dicotomizar variáveis contínuas descarta um terço do poder estatístico da amostra. Por isso, a vetorização pericial humana sobre o ortomosaico de 4 cm é rasterizada na célula de 10 m como uma fração contínua de área erodida $y \in [0, 1]$, ajustada via XGBoost Tweedie (`reg:tweedie`; CHEN; GUESTRIN, 2016).

f(Sentinel-2 10m/20m, MDE Copernicus 30m, Chuva CHIRPS, Pedologia) → Fração Erodida Observada pelo VANT ($y \in [0, 1]$)

3.3 Vieses Residuais Reais e Mecanismos de Neutralização no SAREL

Tipo de Viés Potencial	Mecanismo do Risco	Solução e Controle Estrutural no SAREL
Vazamento Espacial (Spatial Leakage)	Células contíguas do mesmo voo compartilham solo e relevo. Se divididas aleatoriamente entre treino e teste, o modelo 'decora' a fazenda.	**Segregação Mandatória por Polígono (D16):** De 4 polígonos sorteados por estrato, 2 vão para treino e 2 são lacrados como *held-out* de teste independente. Células do mesmo voo nunca se misturam.
Deslocamento Posicional e Borda	Sentinel-2 possui incerteza orbital (2 a 8 m); o VANT possui CE90 de 1,47 m. Um desalinhamento pode atribuir erosão à célula vizinha.	**Alvo Contínuo Tweedie (D26):** O alvo contínuo [0, 1] absorve suavemente incertezas de fronteira, ao contrário de classificadores binários rígidos que sofrem com ruído de rotulagem.
Viés Amostral de Voo e Clima	VANTs só voam sob tempo bom e propriedades autorizadas, enviesando a amostra para fazendas maiores e manejadas.	**Estratificação Biofísica Prévia (D12):** Sorteio probabilístico estrito em 18 estratos cobrindo toda a variação da BP3, impedindo seleção por conveniência.

4. Roteiro Estratégico de Arguição (Scripts de Apresentação e Banca)

Apresentam-se a seguir modelos estruturados de resposta para uso em seminários, qualificações e na defesa final da dissertação. As respostas equilibram fundamentação bibliográfica exata, precisão terminológica e firmeza metodológica.

ROTEIRO 1: RESPOSTA EXECUTIVA RÁPIDA (Seminários Gerais — Tempo: 45 segundos)

*"Agradeço a pergunta, professor(a). Em relação à **replicabilidade**, a natureza probabilística da IA refere-se à inferência matemática e não à aleatoriedade descontrolada. Conforme as diretrizes internacionais de reprodutibilidade em aprendizado de máquina (Pineau et al., 2021), nosso sistema opera com sementes pseudoaleatórias congeladas, ambiente versionado e, crucialmente, validação cruzada espacial em blocos para mitigar a dependência espacial (Roberts et al., 2017). Avaliamos o modelo por distribuições de Bootstrap em 36 polígonos independentes (Cameron et al., 2008), exigindo que o ganho sobre a RUSLE seja comprovado no intervalo de confiança de 95%.*

*Quanto ao **risco de viciar nos dados do drone**, esse problema ocorreria se usássemos o ortomosaico de 4 cm como preditor do modelo para tentar prever em satélite de 10 m, o que geraria o erro clássico de quebra de suporte espacial (Woodcock & Strahler, 1987). No SAREL, o drone **não é preditor**; ele atua na estratégia de 'calibração de modelos' (Alvarez-Vanhard et al., 2021), servindo exclusivamente como verdade de solo. O algoritmo é alimentado apenas por preditores orbitais Sentinel-2 a 10 metros, relevo a 30 metros e variáveis ambientais da bacia. Ele aprende a estimar a fração de área erodida a partir do satélite, sem jamais depender do hiperdetalhe do drone para operar."*

ROTEIRO 2: RESPOSTA APROFUNDADA PARA BANCA EXAMINADORA (Qualificação / Defesa — Tempo: 2 minutos)

"Excelente colocação da banca. Gostaria de responder em dois níveis metodológicos estruturados no SAREL:

***1. Sobre a Replicabilidade e o Não-Determinismo:** Diferenciamos o não-determinismo não controlado da modelagem probabilística reproduzível. Nosso protocolo implementa o tripé de reprodutibilidade científica (Pineau et al., 2021): (a) no nível computacional, os PRNGs são pré-registrados e os artefatos serializados em disco; (b) no nível estatístico, respondemos ao clássico estudo da Nature Communications de Ploton et al. (2020), que provou que modelos ambientais avaliados por validação aleatória comum exibem desempenho ilusório. Adotamos Spatial Block Cross-Validation pelo variograma (Roberts et al., 2017) e Bootstrap agrupado em 36 polígonos independentes (Cameron et al., 2008), reportando sempre o IC 95% da correlação de Spearman; e (c) no nível metodológico, prevenimos o vazamento de dados (data leakage; Kapoor & Narayanan, 2023) e o p-hacking por meio do pré-registro público de regras e critérios de refutação antes da observação dos voos (Nosek et al., 2018).*

***2. Sobre o Vício de Resolução do VANT:** A literatura alerta com razão para o problema da quebra de suporte espacial (Woodcock & Strahler, 1987). Se extraíssemos texturas de 4 cm do Spectral 2 para tentar aplicar na bacia com satélite de 10 m, haveria colapso por MAUP (Openshaw, 1984). Por isso, a arquitetura do SAREL separa rigidamente a **unidade de predição** do **instrumento de rotulagem** (Decisões D06 e D26). A unidade de predição é a célula de 10 m do Sentinel-2. O drone atua exclusivamente na estratégia de model calibration (Alvarez-Vanhard et al., 2021): o especialista delineia a feição sobre o mosaico de 4 cm, e essa feição é convertida na fração contínua [0, 1] dentro da célula de 10 m. Como demonstram Altman e Royston (2006), manter a variável contínua via regressão Tweedie (Chen & Guestrin, 2016) preserva o poder estatístico e absorve erros de borda. Por fim, para neutralizar a dependência espacial entre células do mesmo voo, isolamos 36 polígonos completos como held-out lacrado de teste (Decisão D16), garantindo que o modelo seja testado em áreas onde nunca viu nenhum dado do sensor."*

ROTEIRO 3: PARA BANCA DE COMPUTAÇÃO / CIÊNCIA DE DADOS

"Nosso pipeline trata a modelagem estocástica como processo estritamente auditável sob os padrões NeurIPS (Pineau et al., 2021). Não reportamos acurácias pontuais que poderiam ser fruto de viés de seleção de sementes (seed hacking). Para evitar data leakage geoespacial (Kapoor & Narayanan, 2023), isolamos 36 polígonos inteiros em held-out lacrado e empregamos Spatial Block Cross-Validation guiada por variograma. O modelo XGBoost é formulado com perda Tweedie e restrições de monotonicidade física, garantindo generalização consistente e convergência reprodutível."

ROTEIRO 4: PARA BANCA DE SOLOS / AGRONOMIA / MANEJO

"A erosão laminar não se distribui aleatoriamente; ela segue a hidrodinâmica da vertente e a catena topográfica. O VANT Spectral 2 opera como instrumento de validação pericial de alta precisão (Alvarez-Vanhard et al., 2021), substituindo a subjetividade de estacas pontuais por mapeamento contínuo de microssulcos e colúvios. Ao projetar a área erodida na célula de 10 m do Sentinel-2 como fração contínua, conectamos o detalhe do manejo do solo à escala regional da Bacia do Paraná III, sem distorcer o modelo físico da vertente."

5. Referências Bibliográficas (Norma ABNT NBR 6023)

Todas as obras fundamentais abaixo estão arquivadas fisicamente na base bibliográfica local do repositório (diretórios `docs/Selecao Bibliografica/Pesquisas Machine Learning/`, `docs/Selecao Bibliografica/Para Revisar/` e `docs/verificacoes/fontes/`).

ALTMAN, D. G.; ROYSTON, P. The cost of dichotomising continuous variables. **BMJ (British Medical Journal)**, London, v. 332, n. 7549, p. 1080, 2006. DOI: 10.1136/bmj.332.7549.1080. [Arquivo local: `1080.1.full.pdf`]

ALVAREZ-VANHARD, E.; CORPETTI, T.; HOUET, T. UAV & satellite synergies for optical remote sensing applications: A literature review. **Science of Remote Sensing**, Amsterdam, v. 3, 100019, 2021. DOI: 10.1016/j.srs.2021.100019. [Arquivo local: `UAV--amp--satellite-synergies...pdf`]

BAZZI, C. L.; KRUG, E. T. S.; GOMES, G. J.; SOUZA, E. G. de; GEBLER, L.; SOBJAK, R. Estimating soil loss by laminar erosion using precision agriculture computational tools. **Revista Brasileira de Engenharia Agrícola e Ambiental**, Campina Grande, v. 26, n. 12, p. 907-914, 2022. DOI: 10.1590/1807-1929/agriambi.v26n12p907-914. [Arquivo local: `Estimativa da perda de solo...pdf`]

CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. **The Review of Economics and Statistics**, Cambridge, v. 90, n. 3, p. 414-427, 2008. DOI: 10.1162/rest.90.3.414.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. **Proceedings...** New York: ACM, 2016. p. 785-794. DOI: 10.1145/2939672.2939785. [Arquivo local: `1603.02754v3.pdf`]

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns (Cell Press)**, Cambridge, v. 4, n. 9, 100804, 2023. DOI: 10.1016/j.patter.2023.100804. [Arquivo local: `mmc2.pdf`]

KRUG, E. T. S. **Estimativa de perda de solo por erosão laminar em função de suas características e diferentes níveis de precipitação**. 2024. 88 f. Dissertação (Mestrado em Tecnologias Computacionais para o Agronegócio) — Universidade Tecnológica Federal do Paraná, Câmpus Medianeira, 2024. (Orientador: Prof. Dr. Claudio Leones Bazzi). [Arquivo local: `estimativaerosaolaminar.pdf`]

NOSEK, B. A.; EBERSOLE, C. R.; DEHAVEN, A. C.; MELLOR, D. T. The preregistration revolution. **Proceedings of the National Academy of Sciences (PNAS)**, Washington, v. 115, n. 11, p. 2600-2606, 2018. DOI: 10.1073/pnas.1708274114. [Arquivo local: `nosek-et-al-2018...pdf`]

OPENSHAW, S. **The modifiable areal unit problem**. Norwich: Geo Books, 1984. 41 p. (Concepts and Techniques in Modern Geography, 38).

PINEAU, J.; VINCENT-LAMARRE, P.; SINHA, K.; LARIVIÈRE, V.; BEYGELZIMER, A.; D'ALCHÉ-BUC, F.; FOX, E.; LAROCHELLE, H. Improving reproducibility in machine learning research (A report from the NeurIPS 2019 reproducibility program). **Journal of Machine Learning Research (JMLR)**, Cambridge, v. 22, n. 164, p. 1-20, 2021. [Arquivo local: `20-303.pdf`]

PLOTON, P.; MORTIER, F.; RÉJOU-MÉCHAIN, M.; BARBIER, N.; PICARD, N.; PLOTON, S.; BÉNÉDET, F.; COUTERON, P. Spatial validation reveals poor predictive performance of large-scale ecological mapping models. **Nature Communications**, London, v. 11, n. 1, 4540, 2020. DOI: 10.1038/s41467-020-18321-y. [Arquivo local: `s41467-020-18321-y.pdf`]

RENARD, K. G.; FOSTER, G. R.; WEESIES, G. A.; MCCOOL, D. K.; YODER, D. C. **Predicting soil erosion by water: a guide to conservation planning with the Revised Universal Soil Loss Equation (RUSLE)**. Washington: USDA, 1997. 384 p. (Agriculture Handbook, 703). [Arquivo local: `ah_703.pdf`]

ROBERTS, D. R.; BAHN, V.; CIUTI, S.; BOYCE, M. S.; ELITH, J.; GUILLERA-ARROITA, G.; HAUCH, S.; BLANCHET, F. G.; DORMANN, C. F. Cross-validation strategies for data with temporal, spatial or phylogenetic structure. **Ecography**, Copenhagen, v. 40, n. 8, p. 913-929, 2017. DOI: 10.1111/ecog.02881. [Arquivo local: `Ecography - 2016 - Roberts...pdf`]

WISCHMEIER, W. H.; SMITH, D. D. **Predicting rainfall erosion losses: a guide to conservation planning**. Washington: USDA, 1978. 58 p. (Agriculture Handbook, 537).

WOODCOCK, C. E.; STRAHLER, A. H. The factor of scale in remote sensing. **Remote Sensing of Environment**, New York, v. 21, n. 3, p. 311-332, 1987. DOI: 10.1016/0034-4257(87)90015-0. [Arquivo local: `The_factor_of_scale_in_remote_sensing.pdf`]