

SISTEMA SAREL v2.0

Manual Metodológico, Passo a Passo Operacional e Formulações Matemáticas

Validação e Predição de Erosão Laminar com Sensoriamento Remoto Multitemporal e Gradient Tree Boosting (XGBoost) na Bacia Hidrográfica do Paraná 3 (BP3)

Pesquisador: Luis Alfredo (Mestrando PPGTCA 2026)

Área de Concentração: Tecnologias Computacionais Aplicadas ao Agronegócio e Recursos Hídricos

Linha de Pesquisa: Sensoriamento Remoto, Ciência de Dados e Modelagem Espaço-Temporal

Área de Estudo: Bacia Hidrográfica do Paraná 3 (BP3) — Estado do Paraná, Brasil

Versão do Sistema: 2.0.0 (Homologada em Setembro de 2026)

Normatização: ABNT NBR 6023:2018 (Referências) e NBR 10520:2023 (Citações)

SUMÁRIO ANALÍTICO

- 1. Contexto Científico, Hipótese de Pesquisa e Limitações Espectrais
- 2. Arquitetura Computacional e Distribuição dos Cálculos (GEE vs. Local vs. Planet vs. Jev vs. Treinamento)
- 3. O Subsistema Cognitivo Jev (TypeSafe AI): Propósito, Degradação Graciosa e Blindagem contra Circularidade
- 4. Passo a Passo Operacional do Aplicativo SAREL (Workflow de 10 Etapas)
- 5. Cálculos e Modelos Matemáticos Detalhados (12 Formulações Fundamentais)
- 6. Validação Espaço-Temporal: Modelo D (Detecção) vs. Modelo P (Prognóstico com Guarda Bienal de 24 Meses)
- 7. Governança Científica do Sistema: As 9 Regras Invioláveis e os 7 Invariantes de Integridade
- 8. Referências Bibliográficas Completas segundo as Normas da ABNT (NBR 6023:2018 e NBR 10520:2023)

1. Contexto Científico, Hipótese de Pesquisa e Limitações Espectrais

A erosão laminar é o processo erosivo de maior magnitude em perdas volumétricas de solo na agricultura tropical, consistindo no desprendimento e arraste uniforme e sub-milimétrico das partículas mais férteis dos horizontes superficiais do solo pelo impacto de gotas de chuva (*splash*) e pelo escoamento superficial difuso. No entanto, sua detecção remota via satélite enfrenta um desafio epistemológico e físico seminal apontado na literatura (VRIELING, 2006): **sensores orbitais de média resolução espacial (como o Sentinel-2, com pixel de 10 a 20 metros) não são biofisicamente capazes de mensurar a lâmina de solo perdida diretamente**. O que os sensores registram são *proxies espectrais* da degradação, tais como: (a) o empobrecimento em matéria orgânica; (b) a exposição de horizontes subsuperficiais com enriquecimento de óxidos de ferro; (c) a redução crônica de biomassa vegetal; e (d) a alternância persistente entre solo exposto e palhada residual desprotegida.

A pesquisa de mestrado do PPGTCA/UTFPR tem como objetivo científico central: **validar ou não a localização e predição de erosão laminar utilizando sensoriamento remoto multitemporal e o algoritmo de aprendizado de máquina supervisionado XGBoost (Extreme Gradient Boosting)** na Bacia Hidrográfica do Paraná 3. Para atingir esse objetivo com validade científica reprodutível, o SAREL foi construído para sanar as quatro grandes lacunas críticas identificadas na literatura recente de Machine Learning aplicado a geociências: (1) a suposição ingênua de que resolução espacial de 10 m enxerga diretamente erosão laminar; (2) o vazamento de dados temporal (*data leakage*) provocado pelo treinamento com dados contemporâneos ao dano (KAUFMAN et al., 2012); (3) o viés inflacionário nas métricas de acurácia induzido por validação cruzada aleatória simples na presença de autocorrelação espacial (ROBERTS et al., 2017); e (4) a circularidade metodológica decorrente da utilização de estimativas da RUSLE como rótulos de aprendizado.

2. Arquitetura Computacional e Distribuição dos Cálculos

Para garantir escalabilidade para bacias hidrográficas com milhões de hectares e, simultaneamente, preservar o determinismo físico e a segurança contra vazamento de dados, o SAREL divide suas operações em cinco camadas computacionais bem demarcadas. A tabela a seguir esclarece exaustivamente onde cada cálculo é executado no sistema:

Ambiente / Motor	Tecnologia Subjacente	Cálculos e Procedimentos Realizados	Fundamentação / Propósito
------------------	-----------------------	-------------------------------------	---------------------------

Google Earth Engine (GEE)	API Cloud Python / Earth Engine Service	- Filtragem por máscara QA60/SCL (nuvem/sombra) - Extração de reflectâncias Sentinel-2 L2A (2016-2026) - Declividade contínua (%) do Copernicus DEM 30m - Redução zonal diária CHIRPS e semi-horária IMERG GPM - Máscara agrícola ESA WorldCover e buffers de corpos d'água	Processamento massivo em nuvem sobre petabytes de imagens, sem sobrecarregar a máquina local.
Motor Local SAREL	TypeScript / Node.js (Edge / On-Premise)	- Estratificação 3D (18 estratos: $S^x E^x K^x$) - Spatial Thinning geodésico determinístico (1 km) - Lags multitemporais (t0, t-3m, t-6m, t-12m) - Ajuste harmônico OLS e persistência CCDC - Fator C (Durigon) e Fator K (Embrapa Doc. 246) - Cálculo do Kappa de Cohen e validação dos 7 Invariantes - Cruzamento espacial fundiário com bases SQLite locais	Execução 100% determinística, auditável e reprodutível; não depende de conectividade externa para auditar.
PlanetScope API	API REST Planet (Cenas PSScene 8B)	- Recortes de altíssima resolução espacial (3 metros) - Trios de eventos pluviométricos (T-, T0, T+) - Restrições angulares de visada (Delta zenital ≤ 10 graus) - Insumo visual para interpretação cega da Fase A	Permite identificar feições erosivas sub-pixel Sentinel-2 (microrravinas e incisões laminares severas).
Auditoria Cognitiva Jev	TypeSafe AI Client (System One)	- Julgamento booleano calibrado (Noul) - Classificação de manejo em taxonomia fechada (Choice) - Score ordinal estruturado de suscetibilidade (0 a 4) - Deteção de anomalias espectrais pré-campo	Acelera triagem em lote. Em falhas, comuta automaticamente para o Motor Local RUSLE (Degradação Graciosa).
Ambiente de IA Supervisionada	Python / XGBoost / Scikit-Learn / SHAP	- Treinamento de árvores de gradiente impulsionado - Otimização com regularizações L1/L2 e scale_pos_weight - Spatial Block Cross-Validation com buffer de 1 km - Janela de guarda temporal bienal de 24 meses (Modelo P) - Atribuição de importância física via valores SHAP	Modelagem preditiva externa alimentada exclusivamente por matriz desidentificada e rótulos humanos auditados.

3. O Subsistema Cognitivo Jev (TypeSafe AI): Propósito, Degradação Graciosa e Blindagem contra Circularidade

O **Jev** opera no SAREL como um auditor auxiliar inteligente ('System One'). Ele foi projetado especificamente para superar as fragilidades dos modelos de linguagem gerais, operando sob contratos estritos de tipos (*TypeSafe AI*) que impedem alucinações e garantem respostas em três formatos primitivos:

- **Noul (Julgamento Booleano Calibrado):** Avalia asserções físicas (ex: 'Há indício biofísico de solo exposto sob declive moderado?') retornando true/false associado a uma estimativa de probabilidade/confiança (0.0 a 1.0) e justificativa formal.
- **Choice (Classificação Categórica):** Enquadra a condição observada em uma taxonomia fechada de uso e cobertura do solo ('Plantio Direto Consolidado', 'Solo Exposto Degradado', 'Preparo Reduzido / Vegetação em Desenvolvimento').
- **Score (Escala Ordinal Estruturada):** Avalia o grau ordinal de suscetibilidade em escala de 0 a 4 (0: Nula, 1: Baixa, 2: Moderada, 3: Alta, 4: Crítica).

Mecanismo de Degradação Graciosa (Dual-Engine: Jev vs. Motor Local RUSLE)

O SAREL adota uma arquitetura resiliente de tolerância a falhas. O uso do Jev é uma opção do pesquisador para acelerar a inspeção preliminar de grandes lotes de candidatos e priorizar rotas de campo. Caso a chave de API do Jev não seja configurada, ocorra perda de conectividade de rede, timeout ou quota esgotada, o sistema aciona de forma 100% automática o **MOTOR_LOCAL_RUSLE** determinístico (implementado em `src/lib/jev/fallbackLocal.ts`). O laudo gerado registra a proveniência exata da auditoria e o motivo técnico da comutação (ex: 'Chave do Jev não configurada'), assegurando que o fluxo de trabalho nunca seja interrompido.

A REGRA INVIOLÁVEL 4: Blindagem contra Circularidade Metodológica

É terminantemente proibido utilizar o julgamento, a probabilidade ou o score do Jev como rótulo (target) na matriz de treino do XGBoost! Se um modelo de aprendizado de máquina fosse treinado com previsões geradas por outro modelo de IA ou por equações da RUSLE, ocorreria uma falácia circular destrutiva: a IA aprenderia a imitar aproximações matemáticas pré-existentes, e não a realidade biofísica do terreno. No SAREL, o rótulo da verdade terrestre provém EXCLUSIVAMENTE de observações primárias humanas blindadas (Fase A PlanetScope, Fase B Campo e Fase D Drone).

4. Passo a Passo Operacional do Aplicativo SAREL (Workflow de 10 Etapas)

Passo 1: Delimitação da AOI e Filtragem de Elegibilidade Agrícola

O pesquisador seleciona o limite hidrográfico da Área de Interesse (Bacia do Paraná 3). O sistema consulta a coleção do ESA WorldCover (10 m) e retém exclusivamente as classes agrícolas: 30 (lavouras), 40 (mosaicos agrícolas) e 60 (pastagens manejadas). São aplicadas zonas de exclusão física obrigatórias: faixa de proteção de 30 metros ao longo de corpos d'água e buffer de 150 metros em torno de manchas urbanas e rodovias.

Passo 2: Estratificação Geoespacial Multivariada (18 Estratos Disjuntos)

Para garantir representatividade amostral e mitigar o viés de seleção espacial, a AOI é particionada em 18 estratos tridimensionais ($3 \times 3 \times 2$): (a) Tercis de declividade $S^{\wedge}$ extraídos do Copernicus DEM GLO-30 (Plano/Suave, Moderado, Forte); (b) Tercis de frequência histórica de solo exposto $E^{\wedge}$ extraídos da série multianual Sentinel-2; e (c) 2 níveis de erodibilidade pedológica $K^{\wedge}$ calibrados pela Decisão D09 (Nível 1: $K \leq 0.0285 \text{ t}\cdot\text{h}/(\text{MJ}\cdot\text{mm})$; Nível 2: $K \geq 0.0300 \text{ t}\cdot\text{h}/(\text{MJ}\cdot\text{mm})$).

Passo 3: Rarefação Espacial Geodésica (Spatial Thinning)

Aplica-se o algoritmo determinístico de Fisher-Yates com semente pseudoaleatória controlada e registrada (P07). O thinning impõe uma restrição de distância euclidiana mínima de 1,0 km entre quaisquer pares de pontos selecionados. Isso neutraliza a autocorrelação espacial local redundante (ROBERTS et al., 2017) e impede a concentração viciada de amostras em um único talhão.

Passo 4: Agrupamento em Blocos Espaciais (Spatial Blocks)

Os pontos são agregados em macroblocos poligonais com aresta média de 20 km (P01), dimensão ancorada no alcance de continuidade espacial do semivariograma empírico. Essa partição viabiliza a Validação Cruzada Espacial em Blocos (Spatial Block CV), garantindo que dados de treino e teste pertençam a zonas pedológicas e climáticas distintas.

Passo 5: Extração Multitemporal e Índices Biofísicos Orbitais

Para cada ponto amostral elegível, o SAREL extrai a série histórica completa de reflectâncias de superfície Sentinel-2 L2A (2016 a 2026), filtrando pixels contaminados por nuvem ou sombra via máscara QA60/SCL. São computados os índices NDVI e BSI para cada cena orbital sem nuvem. Exige-se um mínimo de 6 observações válidas por janela temporal (Decisão D11).

Passo 6: Decomposição Harmônica e Discriminação de Persistência Temporal

O motor local ajusta modelos de regressão linear por Mínimos Quadrados Ordinários (OLS) com 1 e 2 ciclos anuais (Zhu & Woodcock, 2014) sobre o NDVI e o SWIR B12. Calcula-se a frequência temporal de solo nu com o limiar estrito $\text{NDVI} \leq 0.25$ (calibrado no sistema GEOS3 por Demattê et al., 2018 e Safanelli et al., 2021 — Decisão D10). Isso separa com rigor físico o pousio agrícola transitório (preparo do solo com rápida recuperação de dossel) da degradação crônica por erosão laminar.

Passo 7: Montagem da Linha de Base RUSLE ($A = R \cdot K \cdot LS \cdot C \cdot P$)

Calcula-se a perda de solo empírica de referência integrando: Fator C (Durigon et al., 2014 / Decisão D01); Fator K numérico contínuo derivado da Tabela 5 da Embrapa Solos (Doc. 246/2024 / Mannigel et al., 2002 — Decisão D14); Fator P conservador (Renard et al., 1997); Fatores R e LS. O Invariante 1 valida rigorosamente que a perda de solo e sua memória de cálculo só existem se os 5 fatores estiverem preenchidos numericamente.

Passo 8: Protocolos Cegos de Rotulagem Multicamada (Fases A, B e D)

Curadoria humana estrita de verdade terrestre: • Fase A (PlanetScope 3 m): Recortes de alta resolução temporal e espacial analisados por dois intérpretes humanos em teste cego, validados via Kappa de Cohen ($k \geq 0.60$); • Fase B (Campo): Vistorias presenciais orientadas por formulário KoboToolbox com cruzamento cadastral fundiário em bases do SICAR, SIGEF e SNCR; • Fase D (Drone): Ortomosaicos centimétricos (2 cm/pixel) isolados como conjunto held-out independente (Regra 6).

Passo 9: Modelagem Preditiva com Gradient Tree Boosting (XGBoost)

A matriz tabular consolidada (contendo variáveis topográficas, climáticas, biofísicas, lags multitemporais e persistência espectral) é exportada com coordenadas desidentificadas e submetida ao treinamento do XGBoost (Chen & Guestrin, 2016). Otimizam-se os hiperparâmetros de regularização (gamma, lambda, alpha) e compensa-se o desbalanceamento amostral severo com `scale_pos_weight`.

Passo 10: Avaliação Espaço-Temporal e Explicabilidade Biofísica via SHAP

O modelo é submetido a duas modalidades de validação: (a) Modelo D (Detecção contemporânea até t_0); e (b) Modelo P (Prognóstico antecipado), isolado por janela de guarda temporal de 24 meses (2 anos) antes do dano (KAUFMAN et al., 2012 — Decisão D04). Os valores SHAP (Lundberg & Lee, 2017) são computados para desvendar a importância marginal de cada preditor e confrontar os resultados com os processos pedológicos da RUSLE.

5. Cálculos e Modelos Matemáticos Detalhados

Síntese Visual das 12 Formulações Canônicas do SAREL:

1. NDVI: $NDVI = \frac{B8 - B4}{B8 + B4}$ (Rouse et al., 1974).

2. BSI: $BSI = \frac{(B11 + B4) - (B8 + B2)}{(B11 + B4) + (B8 + B2)}$ (Rikimaru et al., 2002).

3. Decomposição Harmônica OLS: $\hat{y}(t) = c_0 + c_1 t + \sum_{k=1}^m \left[a_k \cos\left(\frac{2\pi k t}{T}\right) + b_k \sin\left(\frac{2\pi k t}{T}\right) \right]$ (Zhu & Woodcock, 2014).

4. Frequência de Solo Nu ($\hat{E}$): $\hat{E} = \frac{1}{N} \sum_{i=1}^N \ell(NDVI_i \leq 0,25)$ (GEOS3 / Demattê et al., 2018; Safanelli et al., 2021 — Decisão D10).

5. Fator C da RUSLE: $C = \left[\frac{1 - NDVI}{2} \right]^{(1 + NDVI)}$ (Durigon et al., 2014 — Decisão D01).

6. Fator K Numérico: Tabela 5 da Embrapa Solos (Coelho et al., 2024 / Mannigel et al., 2002 — Decisões D09 e D14):

• **Muito baixa (0,0052), Baixa (0,0117), Média (0,0218), Alta (0,0360) e Muito alta (0,0518)** $t \cdot h \cdot MJ^{-1} \cdot mm^{-1}$.

7. RUSLE Consolidada: $A = R \times K \times LS \times C \times P$ (Renard et al., 1997 / Invariante 1).

8. Índice de Mecanismo Dinâmico: $I_{\text{mecanismo}} = \sum_{t=1}^T (R_t \times \ell(NDVI_t \leq 0,25))$ (Modelo G2 / Karydas & Panagos, 2018).

9. Função Objetivo do XGBoost: $\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ (Chen & Guestrin, 2016).

10. Ganho de Divisão em Árvore: $\mathcal{L}_{\text{split}} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$.

11. Kappa de Cohen: $\kappa = \frac{P_o - P_e}{1 - P_e}$ (Landis & Koch, 1977).

12. Valores SHAP: $\phi_i(f, x) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)]$ (Lundberg & Lee, 2017).

1. Índice de Vegetação por Diferença Normalizada (NDVI — ROUSE et al., 1974)

$$\text{NDVI} = \frac{B8 - B4}{B8 + B4}$$

Explicação física: Mede o contraste entre a forte absorção fotossintética da clorofila na banda do Vermelho (B4: 665 nm) e a alta espalhabilidade celular no Infravermelho Próximo (B8: 842 nm). Varia no domínio biofísico [-1.0, +1.0]. Valores > 0.65 caracterizam cobertura vegetal densa e consolidada (Sistema Plantio Direto); valores <= 0.25 caracterizam solo mineralizado exposto.

2. Índice de Solo Exposto (Bare Soil Index — BSI — RIKIMARU et al., 2002)

$$\text{BSI} = \frac{(B11 + B4) - (B8 + B2)}{(B11 + B4) + (B8 + B2)}$$

Explicação física: Combina as bandas do SWIR-1 (B11: 1610 nm) e Vermelho (B4) contra o NIR (B8) e Azul (B2: 490 nm). O solo seco e erodido apresenta forte reflectância no SWIR e absorção no visível, elevando o BSI para valores positivos (> 0.10). Vegetação vigorosa empurra o BSI para valores fortemente negativos (< 0.00).

3. Decomposição Harmônica e Taxa de Degradação OLS (ZHU & WOODCOCK, 2014)

$$\hat{y}(t) = c_0 + c_1 t + \sum_{k=1}^m \left[a_k \cos\left(\frac{2\pi k t}{T}\right) + b_k \sin\left(\frac{2\pi k t}{T}\right) \right]$$

Explicação física: Regressão linear por Mínimos Quadrados Ordinários ajustando componentes sazonais cíclicos (harmônicos anuais e semestrais) e uma componente de tendência linear (c1). O coeficiente c1 na banda SWIR B12 atua como indicador de degradação: declives positivos persistentes safra após safra evidenciam perda de horizonte A orgânico e exposição crônica de horizonte B textural rico em ferro.

4. Frequência Multianual de Solo Exposto (E^ — Decisão D10 / GEOS3)

$$\hat{E} = \frac{1}{N} \sum_{i=1}^N I(\text{NDVI}_i \leq 0,25)$$

Explicação física: Fração temporal em que o solo permaneceu descoberto durante a série histórica. Fundamentada nos trabalhos do sistema GEOS3 (DEMATTE et al., 2018; SAFANELLI et al., 2021), a adoção do limiar estrito NDVI <= 0.25 elimina falsos positivos decorrentes de resíduos secos de palhada de Plantio Direto (que apresentam NDVI entre 0.28 e 0.38).

5. Fator C de Cobertura e Manejo da RUSLE Regional Tropical (DURIGON et al., 2014 — Decisão D01)

$$C = \left[\frac{1 - \text{NDVI}}{2} \right]^{(1 + \text{NDVI})}$$

Explicação física: Modela a atenuação das perdas de solo pela cobertura vegetal sob condições edafoclimáticas brasileiras. Para solo completamente desnudo (NDVI = 0.0), C = 0.50; para cobertura vegetal em desenvolvimento (NDVI = 0.50), C = 0.088; para dossel fechado (NDVI = 0.80), C = 0.026. Supera a formulação exponencial europeia de Van der Knijff et al. (2000), que subestima severamente o Fator C em áreas agrícolas tropicais.

6. Fator K de Erodibilidade do Solo Numérico (Tabela 5 Embrapa Solos / MANNIGEL et al., 2002 — Decisão D14)

$$K \in \{0,0052; 0,0117; 0,0218; 0,0360; 0,0518\} \text{ t} \cdot \text{h} \cdot \text{MJ}^{-1} \cdot \text{mm}^{-1}$$

Explicação física: Converte as 5 classes ordinais qualitativas da carta pedológica oficial da Embrapa Solos (Doc. 246/2024) para grandezas contínuas oficiais. Estratificação K^ (Decisão D09): Nível 1 = Baixa/Média erodibilidade (K <= 0.0285 t·h/(MJ·mm)); Nível 2 = Alta/Muito Alta erodibilidade (K >= 0.0300 t·h/(MJ·mm)). Feições não-agrícolas retornam 'fora-do-dominio'.

Tabela 5 da Embrapa Solos (Doc. 246/2024 / Mannigel et al., 2002 / IBGE, 2018):

Classe Pedológica	Ordinal	Faixa Oficial de K [t·h·MJ ⁻¹ ·mm ⁻¹]	K Médio Adotado	Estrato K^ (D09)
Muito baixa	1	0,0020 a 0,0084	0,0052	Nível 1 (Baixa/Média)
Baixa	2	0,0090 a 0,0144	0,0117	Nível 1 (Baixa/Média)
Média	3	0,0150 a 0,0285	0,0218	Nível 1 (Baixa/Média)
Alta	4	0,0300 a 0,0420	0,0360	Nível 2 (Alta/M. Alta)
Muito alta	5	0,0450 a 0,0585	0,0518	Nível 2 (Alta/M. Alta)

7. Equação Universal de Perda de Solo Revisada (RUSLE — RENARD et al., 1997)

$$A = R \times K \times LS \times C \times P$$

Explicação física: Onde: A é a perda média anual de solo estimada; R é a erosividade da chuva (MJ·mm/(ha·h·ano)); K é a erodibilidade do solo (t·ha·h/(ha·MJ·mm)); LS é o fator topográfico adimensional de comprimento e declive da rampa; C é o fator de uso e cobertura vegetal; e P é o fator de práticas conservacionistas de suporte. Invariante 1: O SAREL impede o cálculo de A se qualquer um dos cinco fatores estiver ausente ou indefinido.

8. Índice de Mecanismo Dinâmico Pluviometria-Exposição (Modelo G2 — KARYDAS & PANAGOS, 2018)

$$I_{\text{mecanismo}} = \sum_{t=1}^T (R_t \times \mathbb{I}(\text{NDVI}_t \leq 0,25))$$

Explicação física: Acopla temporalmente a série de precipitação diária com a condição fenológica do solo. Captura a essência física da erosão hídrica: o impacto de temporais severos de chuva (elevado R_t) incidentes exatamente nos dias em que o terreno agrícola encontrava-se desprotegido de vegetação ou palhada residual (NDVI_t <= 0.25).

9. Função Objetivo Regularizada do XGBoost (CHEN & GUESTRIN, 2016)

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

Explicação física: Otimização em cada iteração de boosting t baseada na expansão em série de Taylor de segunda ordem da função de perda l(yi, y^i). gi e hi representam, respectivamente, o gradiente de primeira ordem e a hessiana de segunda ordem. A penalidade gamma controla o número de folhas T (complexidade da árvore) e lambda controla a regularização L2 sobre os pesos das folhas wj, evitando sobreajuste (overfitting).

10. Critério de Ganho de Divisão de Árvore no XGBoost (Split Gain)

$$\mathcal{L}_{\text{split}} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

Explicação física: Determina de forma exata se a divisão de um nó pai nos nós filhos esquerdo (L) e direito (R) resulta em redução de perda estatística suficiente para compensar o custo de regularização gamma da árvore. Se Gain <= 0, o algoritmo realiza a poda (pruning) do ramo.

11. Concordância Inter-intérpretes (Índice Kappa de Cohen — LANDIS & KOCH, 1977)

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

Explicação física: Calcula a concordância observada (Po) corrigida pelo efeito puramente casual do acaso (Pe) entre dois fotointérpretes humanos independentes que avaliaram cegamente a presença de erosão laminar nas imagens de alta resolução PlanetScope (Fase A). Valores de kappa >= 0.60 asseguram concordância substancial e aprovam o ponto amostral para a matriz de treino.

12. Valores SHAP de Explicabilidade Aditiva (LUNDBERG & LEE, 2017)

$$\phi_i(f, x) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F|-|S|-1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)]$$

Explicação física: Calcula a contribuição marginal de cada preditor *i* na probabilidade final de erosão predita pelo XGBoost, ancorado na teoria dos jogos cooperativos de Shapley. Permite responder com rigor científico: 'Quais variáveis biofísicas foram determinantes para classificar este ponto como erodido?' — abrindo integralmente a 'caixa-preta' do algoritmo.

6. Validação Espaço-Temporal: Modelo D (Detecção) vs. Modelo P (Prognóstico com Guarda Bienal)

Uma das inovações metodológicas cruciais do SAREL reside na **segregação formal entre o problema de detecção contemporânea e o problema de prognóstico preventivo**. Na literatura comum, modelos frequentemente utilizam imagens da mesma safra do dano para 'prever' erosão, o que incorre em vazamento severo de informação (*data leakage* — KAUFMAN et al., 2012): o algoritmo não aprende a prever o risco futuro, mas apenas a identificar que o solo já está destruído.

Critério Metodológico	Modelo D (Detecção Contemporânea)	Modelo P (Prognóstico Preventivo)
Objetivo Científico	Mapear a ocorrência contemporânea da feição erosiva que já se consolidou no terreno.	Estimar a suscetibilidade e probabilidade futura de ocorrência de erosão ANTES que o dano ocorra.
Janela Temporal Permitida	Série temporal orbitando continuamente até a data exata da observação (t0).	Série temporal truncada com janela de guarda obrigatória de 24 meses (2 anos) antes de t0 (Decisão D04).
Fundamentação da Guarda	Não se aplica (cenário pericial contemporâneo).	Kaufman et al. (2012) e ciclo de rotação de culturas bienal soja-milho safrinha da Embrapa Soja.
Sinais Biofísicos Chave	Horizonte B exposto, BSI > 0.10, ausência drástica de biomassa verde.	Histórico de manejo, baixa rotação de palhada, persistência de solo nu em safras passadas, declividade e erodibilidade.
Estratégia de Validação Cruzada	Spatial Block Cross-Validation (ROBERTS et al., 2017) com buffer geodésico de 1 km.	Spatial Block Cross-Validation combinado com Particionamento Temporal Estrito (Roberts et al., 2017).
Utilidade Prática no Agronegócio	Perícia judicial de crimes ambientais, quantificação de passivos, fiscalização de órgãos de controle.	Planejamento conservacionista preditivo, concessão de crédito rural sustentável, precificação de seguro agrícola.

7. Governança Científica do Sistema: As 9 Regras Invioláveis e os 7 Invariantes de Integridade

A integridade computacional do SAREL é garantida por testes automatizados contínuos que bloqueiam qualquer desvio metodológico ou inserção de dados artificiais. O sistema é regido por **9 Regras Invioláveis** e **7 Invariantes**:

- Regra 1 — Sem Valores Fabricados:** É terminantemente proibido o uso de valores padrão artificiais ou operadores de coalescência com fallbacks numéricos. Se a fonte não responde, o dado é estritamente encapsulado como indisponível.
- Regra 2 — Sem Cortes Silenciosos:** Proibição de truncamentos artificiais com funções de mínimo ou máximo para mascarar dados anômalos. Violações de domínio físico geram exceções formais ou fora-do-dominio.
- Regra 3 — Rastreabilidade e Proveniência Universal:** Toda grandeza científica manipulada implementa o tipo discriminado Proveniencia (medido, modelado, tabelado, indisponível) com registro de fonte, instrumento e timestamp.

Regra 4 — Nada Calculado Vira Rótulo (Anti-Circularidade): Modelos matemáticos (RUSLE) ou motores de IA (Jev) JAMAIS definem a verdade terrestre da matriz de treinamento.

Regra 5 — Guarda Antissintética Universal: O sistema bloqueia recursivamente qualquer ponto amostral que possua a flag origemSintetica: true.

Regra 6 — Segregação Cega de Exportação: As equipes de interpretação e a matriz de treino recebem artefatos desidentificados (sem coordenadas geográficas), impedindo que o algoritmo aprenda localização espacial em vez de processos físicos.

Regra 7 — Preservação de Máscaras Orbitais: Pixels afetados por nuvens ou sombras não são preenchidos por interpolação artificial; são preservados como descontinuidades reais na série temporal.

Regra 8 — Evidência Física de Verificação: Comentários no código alegando verificação de fontes exigem arquivamento de prova auditável no diretório docs/verificacoes/.

Regra 9 — Preservação Histórica e Reprodutibilidade: Versionamento contínuo em Git (branch sare/v2) com sementes pseudoaleatórias registradas a cada execução.

Os 7 Invariantes de Integridade Computacional (validados em invariantes.ts):

- **Invariante 1 (Coerência RUSLE):** A perda de solo só existe se, e somente se, os cinco fatores (R, K, LS, C, P) e a memória de cálculo existirem simultaneamente com valores finitos.
- **Invariante 2 (Lista de Permissão Estrita):** Bloqueia o vazamento de variáveis internas protegidas (como phi_diag ou coordenadas em matrizes de treino).
- **Invariante 3 (Derivação Fidedigna):** Campos_Estimados são computados estritamente a partir de variáveis com estado diferente de 'medido'.
- **Invariante 4 (Rastreabilidade Orbital):** Dados orbitais exigem lista explícita de PRODUCT_ID, versão do motor de processamento e timestamp de consulta.
- **Invariante 5 (Afirmção Negativa Fundiária):** A atribuição de 'sem-correspondencia' fundiária exige evidência de consulta válida aos bancos do SICAR/SIGEF sem sobreposição espacial.
- **Invariante 6 (Proibição de Literais Espúrios):** Rejeita termos fictícios nos atributos territoriais (como 'Custom' ou 'Bacia Local').
- **Invariante 7 (Detector de Constante Disfarçada):** Recusa a exportação se qualquer coluna numérica apresentar variância zero (mesmo valor em todas as linhas para n >= 21).

8. Referências Bibliográficas (Normas ABNT NBR 6023:2018 e NBR 10520:2023)

A seguir relacionam-se todas as publicações técnico-científicas canônicas que fundamentam os pilares teóricos, algorítmicos e pedológicos do SAREL, formatadas rigorosamente de acordo com a ABNT NBR 6023:2018:

- COELHO, M. R. et al. **Erodibilidade dos solos do Brasil**. Rio de Janeiro: Embrapa Solos, 2024. 38 p. (Documentos / Embrapa Solos, n. 246). Disponível em: <http://www.infoteca.cnptia.embrapa.br/infoteca/handle/doc/1170044>.
- CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. **Proceedings [...]**. New York: ACM, 2016. p. 785–794. DOI: 10.1145/2939672.2939785.
- DEMATTE, J. A. M. et al. Geospatial Soil Sensing System (GEOS3): A powerful data mining procedure to retrieve soil spectral reflectance from satellite images. **Remote Sensing of Environment**, v. 212, p. 161–175, 2018. DOI: 10.1016/j.rse.2018.04.047.
- DURIGON, V. L. et al. NDVI-based C-factor estimation for RUSLE in Brazilian watersheds. **Revista Brasileira de Ciência do Solo**, Viçosa, v. 38, n. 3, p. 726–734, 2014. DOI: 10.1590/S0100-06832014000300003.
- IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Manual Técnico de Pedologia**. 3. ed. Rio de Janeiro: IBGE, 2018. 142 p. (Manuais Técnicos em Geociências, n. 4).
- KARYDAS, C. G.; PANAGOS, P. The G2 erosion model: month-time step assessments at regional scale. **Environmental Research**, v. 161, p. 115–124, 2018. DOI: 10.1016/j.envres.2017.11.002.

- KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data (TKDD)**, v. 6, n. 4, p. 1–21, 2012. DOI: 10.1145/2382577.2382579.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, v. 33, n. 1, p. 159–174, 1977. DOI: 10.2307/2529310.
- LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NEURIPS 2017), 30., 2017, Long Beach. **Proceedings [...]**. Red Hook: Curran Associates, 2017. p. 4765–4774.
- MANNIGEL, E. et al. Fator erodibilidade de solos do estado de São Paulo. **Revista Brasileira de Ciência do Solo**, Viçosa, v. 26, n. 4, p. 1039–1049, 2002. DOI: 10.1590/S0100-06832002000400024.
- RENARD, K. G. et al. **Predicting soil erosion by water: a guide to conservation planning with the Revised Universal Soil Loss Equation (RUSLE)**. Washington, D.C.: United States Department of Agriculture, 1997. 404 p. (Agriculture Handbook, n. 703).
- RIKIMARU, A.; ROY, P. S.; MIYATAKE, S. Tropical forest cover density mapping. **Tropical Ecology**, v. 43, n. 1, p. 39–47, 2002.
- ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, or hierarchical structure. **Ecography**, v. 40, n. 8, p. 913–929, 2017. DOI: 10.1111/ecog.02881.
- ROUSE, J. W. et al. Monitoring the vernal advancement and retrogradation (Greenwave effect) of natural vegetation. **NASA/GSFC Type III Final Report**, Greenbelt, p. 1–371, 1974.
- SAFANELLI, J. L.; DEMATTÊ, J. A. M. et al. Fine-scale soil mapping with Earth Observation data: a multiple geographic level comparison. **Revista Brasileira de Ciência do Solo**, Viçosa, v. 45, e0210080, p. 1–20, 2021. DOI: 10.36783/18069657rbs20210080.
- TOBLER, W. R. A computer movie simulating urban growth in the Detroit region. **Economic Geography**, v. 46, sup. 1, p. 234–240, 1970. DOI: 10.2307/143141.
- VAN DER KNIJFF, J. M.; JONES, R. J. A.; MONTANARELLA, L. **Soil erosion risk assessment in Italy**. Ispra: European Soil Bureau, Joint Research Centre (JRC), European Commission, 2000. 52 p. (EUR 19022 EN).
- VRIELING, A. Satellite remote sensing for water erosion assessment: A review. **Catena**, v. 65, n. 1, p. 2–18, 2006. DOI: 10.1016/j.catena.2005.10.005.
- ZHU, Z.; WOODCOCK, C. E. Continuous change detection and classification of land cover using all available Landsat data. **Remote Sensing of Environment**, v. 144, p. 152–171, 2014. DOI: 10.1016/j.rse.2014.01.011.