

Planejamento de Pesquisa — Localização e Predição de Erosão Laminar

Objetivo da pesquisa: validar um método de localização e predição de erosão laminar a partir de variáveis de terreno, espectrais e de regime de chuvas, com modelo supervisionado (XGBoost).

Restrição superveniente: o drone multiespectral não está disponível para a fase de treinamento. Passa a ser instrumento de validação final.

Documento: planejamento das duas hipóteses de desenho experimental e redefinição do escopo do aplicativo. **Data:** 08/09/2026

1. O que muda ao redefinir o objetivo

O aplicativo foi construído para **eleger focos de erosão** e emitir um laudo com perda de solo pela RUSLE. O objetivo real é outro: **produzir dados de treino e validar um método preditivo**. São coisas diferentes, e a diferença não é de implementação — é de papel.

	Papel antigo	Papel novo
Pipeline GEE	decide onde há erosão	propõe onde ir observar
Φ / severidade	é o resultado	é apenas um critério de amostragem
RUSLE	é o produto final	é a linha de base de comparação
Rótulo	inexistente (tudo é positivo)	vem exclusivamente da observação
Tabela Consolidada	peça pericial	matriz de treino com proveniência

Essa mudança resolve sozinha o problema mais grave que a auditoria não tinha como enxergar: hoje o rótulo do sistema (severity) é função determinística de quatro variáveis brutas — declividade, BSI, areia e argila, via $\Phi = \text{declividade} \times 0,40 + \text{BSI} \times 50 + \Psi_{\text{solo}}$. Treinar XGBoost com essas features e esse rótulo produziria um modelo que reconstrói os limiares 28,0 e 48,0 com acurácia quase perfeita **sem ter aprendido nada sobre erosão**.

Regra que rege todo o desenho a partir daqui:

Nenhuma quantidade calculada pelo sistema pode ser usada como rótulo. O rótulo vem de observação — de campo, de interpretação de imagem ou de drone. O sistema só produz features e sugestões de onde observar.

2. A decisão que precede as duas hipóteses

Antes de escolher entre H1 e H2, é preciso responder uma pergunta que nenhuma das duas resolve:

O que conta como "erosão laminar presente"?

Sem uma **definição operacional escrita antes de qualquer coleta**, os dois desenhos falham igualmente — porque rótulos inconsistentes limitam o desempenho do modelo mais do que qualquer escolha de algoritmo.

A definição precisa ser: (a) observável pelo instrumento escolhido; (b) aplicável por duas pessoas com o mesmo resultado; (c) registrada antes de olhar os dados.

Indicadores candidatos, do mais objetivo ao mais interpretativo:

Indicador	Campo	Drone MS	Imagem VHR
Espessura do horizonte A (trado/mini-trincheira)	Sim direto	Não	Não
Exposição do horizonte B (mudança de cor do solo)	Sim	Sim	parcial
Pedestais de erosão / raízes expostas	Sim	parcial	Não
Início de sulcos (microrravinas)	Sim	Sim	parcial
Deposição de sedimento em sopé de rampa	Sim	Sim	Sim
Vigor diferencial da cultura em manchas	parcial	Sim	Sim

Recomendação: adotar um critério **composto e graduado** (ausente / incipiente / moderada / severa) registrado em campo, e colapsá-lo para binário na modelagem. Guardar o grau permite, depois, testar o modelo como classificador binário e como ordinal, e permite excluir a classe "incipiente" do treino para afiar a fronteira — recurso padrão quando a classe intermediária é ambígua.

Ponto crítico: confirmar **ausência** de erosão laminar é mais difícil que confirmar presença. A erosão laminar é sutil — essa é a premissa do projeto inteiro. O critério de negativo precisa ser tão explícito quanto o de positivo, ou o negativo vira "não vi nada", que não é a mesma coisa que "não há".

3. Hipótese 1 — Drone multiespectral para treinamento

(desenho original, hoje inviável; documentado para comparação e para o caso de o drone ser recuperado)

3.1 Geração do rótulo

- Selecionar **N talhões** de 10–30 ha, estratificados no espaço de features (declividade × erodibilidade × cobertura).
- Voo multiespectral, GSD 5–10 cm, ortomosaico + índices espectrais de alta resolução.
- Delimitação de **polígonos** de mancha erosiva sobre o ortomosaico, com verificação em campo de uma subamostra.
- Rasterização dos polígonos para a grade de predição.

3.2 A decisão de escala — onde este desenho costuma falhar

O drone rotula a 5–10 cm. O modelo prediz na grade do Sentinel-2 (10 m) e do DEM (30 m). É preciso uma regra de agregação explícita:

Um pixel de 10 m é positivo se $\geq X\%$ da sua área estiver dentro de mancha erosiva.

- Sugestão: $X = 40\%$, com teste de sensibilidade em 30% e 50%.
- **Recurso recomendado:** descartar do treino os pixels *mistos* ($10\% < \text{cobertura} < 40\%$). Afia a fronteira de decisão e reduz ruído de rótulo. Custa amostra, ganha qualidade.

3.3 A armadilha central: features de inferência

O drone fornece o RÓTULO, nunca a FEATURE.

Se o modelo for treinado com bandas ou índices derivados do drone, ele só poderá prever onde houve voo — o que anula o propósito do método. As features precisam ser exatamente as mesmas disponíveis em qualquer ponto do estado: Sentinel-2, DEM, clima e solo.

3.4 Tamanho de amostra — a vantagem real de H1

Um voo de 20 ha = 200.000 m² ≈ **2.000 pixels Sentinel de 10 m rotulados**. Dez voos ≈ 20.000 pixels.

Mas atenção ao que isso significa de fato: pixels do mesmo voo são fortemente autocorrelacionados. O **número efetivo de unidades independentes é o número de sítios, não de pixels**. Dez voos são dez unidades. Para sustentar uma afirmação de generalização, o desenho precisa de **20–30 sítios independentes**, bem distribuídos.

Consequência obrigatória: validação cruzada **agrupada por voo** (GroupKFold), jamais aleatória por pixel. Um k-fold aleatório aqui produziria acurácia de 0,95 e nenhum poder preditivo real.

3.5 Riscos de H1

- Regra de agregação de escala é arbitrária e influencia o resultado.
- Poucas unidades independentes, apesar do volume aparente de dados.
- Viés na escolha dos talhões de voo (tende-se a voar onde já se sabe que há erosão).
- **Viés compartilhado entre treino e validação**: mesmo sensor, mesmo intérprete, mesmo critério. A validação mede consistência, não correção.
- Dependência de um equipamento — risco que já se materializou.

4. Hipótese 2 — Drone somente para validação final

(desenho viável hoje)

O rótulo de treino precisa vir de outra fonte. Três alternativas, avaliadas honestamente:

4.1 Fontes de rótulo

Opção A — Interpretação visual em imagem de altíssima resolução

- Fontes gratuitas a verificar: **PlanetScope/NICFI** (~4,7 m, programa gratuito para os trópicos — confirmar cobertura do Paraná), **CBERS-4A/WPM** (INPE, 2 m PAN / 8 m MUX, gratuito), acervo histórico do Google Earth (altíssima resolução, uso apenas visual).
- Protocolo obrigatório: critério escrito, **dois intérpretes independentes**, medida de concordância (Kappa de Cohen), terceiro intérprete para desempate.
- **Vantagem**: escalável e barata — permite centenas de pontos.
- **Limitação séria**: só detecta erosão laminar **já avançada** (subsolo exposto, manchas claras, deposição em sopé). A incipiente é invisível nessa resolução.
- **Consequência a declarar na dissertação**: o modelo aprenderá a detectar erosão laminar avançada. É um domínio de validade legítimo, desde que explicitado.

Opção B — Campanha de campo convencional


- GPS + trado ou mini-trincheira + ficha padronizada de avaliação.
- Indicadores objetivos: espessura do horizonte A, exposição do B, pedestais, marcas em colo de raiz, deposição em sopé.
- **Vantagem**: rótulo de alta qualidade e capaz de detectar a erosão incipiente, que é justamente o alvo científico mais interessante.
- **Limitação**: ~15–30 pontos por dia com equipe; custo de deslocamento domina.
- **Já existe infraestrutura no projeto**: `koboParser.ts` e o componente `KoboFieldImport` importam formulários do KoboToolbox e marcam o ponto como `field-validated`, com as observações preservadas como vieram. É a espinha dorsal pronta para este desenho.

Opção C — Inventários de erosão existentes

- IAT, Embrapa Solos, ITCG, teses anteriores na região.

- [!] **Advertência metodológica:** mapas de *susceptibilidade à erosão* são **modelos**, não observações — em geral derivados de declividade e solo, as mesmas variáveis que serão features. Treinar neles é destilar outro modelo, não validar um método novo. **Só serve inventário de erosão observada e mapeada em campo.**

4.2 Desenho recomendado para H2 — cadeia em quatro fases



A Fase B é o que torna a Fase A defensável: sem ela, a interpretação visual é uma opinião; com ela, é uma medição com incerteza conhecida.

4.3 A vantagem científica que H2 tem sobre H1

Este é o argumento que transforma a restrição em virtude, e vale colocar na dissertação:

*Em H1, treino e validação compartilham sensor, intérprete e critério. Erro sistemático de rotulagem se propaga igualmente aos dois — a validação confirma **consistência**, não **correção**.*

*Em H2, o rótulo de treino (interpretação + campo) e o de validação (drone multiespectral) são **metodologicamente independentes**. A validação passa a testar se o método generaliza **através de modalidades de observação**. É evidência substancialmente mais forte de que o método funciona.*

4.4 Riscos de H2

- Rótulo mais ruidoso → teto de desempenho do modelo mais baixo. XGBoost tolera bem ruído **aleatório**; ruído **sistemático** (ex.: intérprete que sempre subestima em solo escuro) é destrutivo. Daí a exigência dos dois intérpretes e do Kappa.
- Domínio restrito à erosão avançada, se a Fase B não corrigir.
- Custo de campo concentrado na Fase B.

5. Comparação e recomendação

Critério	H1 — drone no treino	H2 — drone só na validação
Qualidade do rótulo	Alta	Média (alta na subamostra de campo)
Volume de rótulos	Muito alto (pixels)	Médio (pontos)
Unidades independentes	Baixo (nº de voos)	Alto (pontos dispersos)
Detecta erosão incipiente	Sim	Só via campo (Fase B)
Força lógica da validação	Fraca (viés compartilhado)	Forte (modalidade independente)
Custo	Alto e concentrado	Médio e distribuído
Viabilidade hoje	Inviável	Viável

Critério	H1 — drone no treino	H2 — drone só na validação
Risco de ponto único de falha	Alto (equipamento)	Baixo

Recomendação: H2 — e não apenas por necessidade

A independência entre a modalidade de rotulagem do treino e a da validação é uma **melhoria real do desenho experimental**, não um consolo. Uma banca aceita mais facilmente "treinei com interpretação corrigida por campo e validei com drone" do que "treinei e validei com o mesmo drone e o mesmo intérprete".

Vale ainda registrar um caminho híbrido: **se o drone ficar disponível para 5–8 voos**, o melhor uso não é treinar — é entrar como **terceira modalidade na Fase B**, medindo a taxa de erro da interpretação visual com precisão muito maior que o campo isolado. Isso fortalece toda a cadeia sem comprometer a independência da Fase D.

6. Regime de chuvas — onde eu apostaria o ganho preditivo

Você citou o regime de chuvas como variável do método. Hoje o sistema usa **climatologia da NASA POWER, médias mensais de 2001–2020, resolução ~55 km**, para produzir um Fator R anual.

Isso é adequado para a RUSLE, e **inadequado como feature de um modelo local**: dentro de uma AOI municipal ou de sub-bacia, essa variável é praticamente constante. Uma feature constante não carrega informação.

Erosão laminar responde a **eventos**, não a médias. O que provavelmente prediz é o histórico recente de chuva antes da imagem:

Feature proposta	Fonte
Precipitação acumulada 30 / 60 / 90 dias antes da cena	CHIRPS diário (UCSB-CHG/CHIRPS/DAILY, ~5,5 km)
Intensidade máxima diária no período	CHIRPS / GPM IMERG
Nº de eventos erosivos (> 10 mm/dia)	CHIRPS diário
Maior sequência de dias secos antes do evento	CHIRPS diário
Erosividade EI30 acumulada da estação corrente	derivada de CHIRPS

Todas as fontes já são acessíveis dentro do próprio Earth Engine, no mesmo `reduceRegion` das demais bandas — sem chamada de rede adicional por ponto.

Complemento de alto valor — features temporais espectrais. Para erosão laminar, a **frequência de exposição de solo nu durante a estação chuvosa** deve prever melhor do que um BSI de data única: nº de meses com BSI acima do limiar, BSI máximo do ciclo, amplitude anual de NDVI. Combinado com a chuva do mesmo período, aproxima-se do mecanismo físico real — chuva erosiva incidindo sobre solo descoberto.

Se eu tivesse que escolher **uma** mudança de maior retorno preditivo neste projeto, seria esta: sair da fotografia de data única para a série temporal, tanto no espectral quanto na chuva.

7. O aplicativo — novo escopo

7.1 O que ele passa a ser

*Não é um eleitor de focos de erosão. É um **desenhador de amostragem e gerenciador de campanha de rotulagem**.*

Sete funções, nesta ordem de importância:

1. **Frame de amostragem** — máscara de elegibilidade (uso do solo, faixa de declividade, exclusão de água e área urbana) definindo o universo de onde se pode amostrar. *Já existe e funciona.*
2. **Estratificação do espaço de features** — hoje 6 estratos (3 classes de declividade × 2 grupos de erodibilidade). *Existe; precisa ampliar para incluir cobertura/uso e faixa de chuva.*
3. **Amostragem com espalhamento, não com seleção do topo** — [!] **mudança conceitual central.** Hoje `thinBySpacing()` entrega os pontos de maior score. Para treino é preciso o oposto: cobrir toda a faixa de Φ , incluindo deliberadamente os pontos de Φ baixo, que são os candidatos a **classe negativa**. Amostragem por quantis, não Top-N.
4. **Exportar plano de campo** — navegação até os pontos, ficha de coleta, formulário Kobo. *Parcialmente existe.*
5. **Ingerir rótulos** — Kobo (campo), interpretação visual, resultados de drone, cada um com sua modalidade registrada. `koboParser` *existe e é boa base.*
6. **Montar a matriz de treino com proveniência por variável** — features + rótulo + modalidade + intérprete + data. *Não existe.*
7. **RUSLE como linha de base de comparação** — deixa de ser produto e passa a ser o *benchmark* contra o qual o XGBoost será comparado. É um resultado forte de dissertação: "o modelo supervisionado supera a **RUSLE** em X". Mas exige que a **RUSLE** esteja **correta**, porque não se compara contra uma linha de base quebrada.

7.2 Requisitos que decorrem do uso em aprendizado de máquina

- **Nenhuma constante de preenchimento.** Valor ausente é `null`, nunca 0,32 / 0,45 / 16. Em modelo de árvore, valor constante vira divisão em valor exato e o modelo aprende o artefato. XGBoost trata `NaN` nativamente — deixar ausente é **melhor** que imputar.
- **Nenhuma feature derivada do rótulo.** Fora da matriz: `severity`, `priorityScore`, `estimatedSoilLoss`, `featureType`, `stratumId` e os cinco fatores **RUSLE** (funções determinísticas das brutas — colineares e sem informação adicional).
- **Proveniência por variável**, para permitir remover do treino, depois, tudo que não for medição.
- **Bloco espacial exportado junto** com cada ponto, para viabilizar validação cruzada espacial. O *thinning* de 1 km não elimina autocorrelação de solo e relevo — k-fold aleatório inflaria a acurácia.
- **Rotulagem cega:** quem rotula não pode ver o score algorítmico do ponto. Caso contrário, mede-se viés de confirmação. O app deve ser capaz de **exportar a lista de campo sem as colunas de predição**.

7.3 O que aproveitar do código atual

Recomeçar do conceito, não do código. Há subsistemas bons demais para descartar:

Manter	Por quê
<code>eligibilityMask.ts</code> + <code>eligibilityConstants.ts</code>	frame de amostragem correto e parametrizado
<code>stratification.ts</code> + estratos A1–B3	desenho de estratificação adequado
<code>spatialThinning.ts</code>	dispersão geográfica; muda o critério, não o algoritmo
<code>aoiTiling.ts</code>	particionamento para não estourar cota do GEE
<code>koboParser.ts</code> + <code>KoboFieldImport</code>	ingestão de rótulo de campo — base pronta para H2
<code>spatialMatcher.py</code> + base fundiária	contexto de manejo e acesso à propriedade para campo
<code>sessionStore</code> / <code>localOnly</code> / <code>isSyntheticPoint</code>	segurança e integridade, auditados e corretos
<code>xlsxWriter</code> + infraestrutura de export	funciona e gera arquivo válido

Descartar ou reposicionar	Por quê
<code>severity</code> , <code>priorityScore</code> como resultado	viram critério interno de amostragem
<code>Defaults</code> de <code>parsers.ts</code>	substituir por ausência explícita

Descartar ou reposicionar	Por quê
<code>inferPedologyClass</code>	substituir pela carta real da Embrapa
Cálculo de perda de solo como produto	vira linha de base de comparação
Bônus CAR no score exportado	separar em <code>selectionScore</code> interno

7.4 Sobre os dados da Embrapa

Registrado na auditoria e ainda mais relevante agora: as duas camadas da Embrapa no app (`parana_solos_20201105` e `brasil_erodibilidade_solo`) são requisições WMS `format=image/png` — **imagem decorativa, não consultável**. E o SoilGrids, segundo o próprio teste do projeto, **retorna nulo para o Brasil**.

Como **features de solo são centrais** no seu método, isso deixa de ser um item de correção e passa a ser **pré-requisito**: consultar as cartas da Embrapa por valor no ponto (`WMS GetFeatureInfo` ou `WFS GetFeature`; alternativamente ingerir como *asset* no Earth Engine e amostrar no mesmo `reduceRegion`).

8. Sequência de execução proposta

- ETAPA 0 Definição operacional do rótulo (§2)
Escrita, revisada com o orientador, ANTES de qualquer coleta.
Sem isso, nada depois tem validade.
- ETAPA 1 Features de verdade
- Solo real da Embrapa (substitui `inferPedologyClass`)
 - Chuva diária CHIRPS (substitui climatologia)
 - Séries temporais BSI/NDVI
 - Eliminar toda constante de preenchimento
- ETAPA 2 Amostragem para treino
- Amostragem por quantis de Φ , não Top-N
 - Negativos do mesmo frame de elegibilidade
 - Blocos espaciais atribuídos
 - Export de campo CEGO (sem colunas de predição)
- ETAPA 3 Campanha de rotulagem (H2, Fases A e B)
- Interpretação visual: 2 intérpretes + Kappa
 - Campo em subamostra: mede a taxa de erro
 - Ingestão via Kobo
- ETAPA 4 Modelagem
- Matriz só com medição bruta + temporal + chuva
 - Validação cruzada espacial por blocos
 - Linha de base: RUSLE corrigida
 - Métricas honestas para classe desbalanceada (AUC-PR, não só acurácia)
- ETAPA 5 Validação final (H2, Fase D)
- Drone multiespectral em áreas held-out
 - Nunca vistas em nenhuma etapa anterior

A **Etapla 0 é bloqueante**. As demais podem sobrepor-se parcialmente.

9. Pontos para decidir com o orientador

#	Questão	Impacto
1	Definição operacional de "erosão laminar presente" e de "ausente"	Determina tudo o que vem depois

#	Questão	Impacto
2	Binário ou ordinal (ausente / incipiente / moderada / severa)?	Desenho do modelo e da ficha de campo
3	Domínio de validade: apenas 3–20% de declividade e uso agrícola?	Restringe a inferência; precisa ser declarado
4	Unidade de predição: pixel de 10 m, de 30 m, ou talhão?	Muda features, rótulo e validação
5	Nº de pontos de campo viável no cronograma	Fixa o teto de desempenho do modelo
6	Forma do Fator C na RUSLE ([!]) inversão documentada na auditoria)	Só afeta a linha de base, não o XGBoost — mas a linha de base precisa estar certa
7	A RUSLE entra como comparação ou sai do escopo?	Define se as correções C1/C2 são necessárias

10. Riscos principais do projeto

1. **Rótulo mal definido** — risco nº 1, e não é técnico. Nenhum ajuste de modelo compensa rótulo inconsistente.
2. **Vazamento de alvo** — usar qualquer quantidade calculada pelo sistema como rótulo produz acurácia excelente e conhecimento zero. Mitigado pela regra da §1.
3. **Autocorrelação espacial** — k-fold aleatório infla a acurácia. Mitigado por blocos espaciais.
4. **Amostra pequena** — o teto do modelo é fixado pelo número de rótulos, não pela qualidade do código. Dimensionar cedo.
5. **Desbalanceamento de classes** — se os positivos forem raros no frame, acurácia é métrica enganosa. Usar AUC-PR e reportar a prevalência.
6. **Viés de confirmação na rotulagem** — mitigado por rotulagem cega ao score.
7. **Extrapolação fora do domínio treinado** — declarar o domínio de validade em vez de predizer em todo o estado sem ressalva.

Documento derivado da auditoria de 08/09/2026 e da redefinição de objetivo discutida na mesma data. Os itens sobre fontes de dados externas (NICFI, CBERS-4A, CHIRPS, GPM IMERG, cartas da Embrapa) precisam de confirmação de cobertura e de condições de uso antes de serem incorporados ao desenho definitivo.