

Planejamento de Pesquisa v2 — Localização e Predição de Erosão Laminar

Objetivo: validar um método de localização e predição de erosão laminar a partir de séries temporais multiespectrais, variáveis de terreno e solo, e regime de chuvas, com modelo supervisionado (XGBoost).

Arquitetura de dados: Google Earth Engine (série histórica, terreno, solo, chuva) + Planet/PlanetScope (pares de evento em alta revisita) + drone multiespectral (validação final planejada).

Substitui: PLANEJAMENTO_PESQUISA_2026-09-08.md (v1), mantido para referência. **Data:** 08/09/2026

1. Decisões já consolidadas

Questão	Decisão
Papel do drone	Validação final , em áreas selecionadas, com voo planejado
Fonte do rótulo de treino	Interpretação em alta resolução + campo (nunca cálculo do sistema)
Série temporal	Eixo central do método, não refinamento
Imageamento por evento	Pares antes/depois de chuva erosiva, via Planet
Chuva	CHIRPS + GPM IMERG (globais, no GEE). SIMEPAR opcional
RUSLE	Linha de base de comparação , não produto
Credenciais	Setor seguro do próprio aplicativo (padrão já existente)

A regra que rege todo o desenho

Nenhuma quantidade calculada pelo sistema pode ser usada como rótulo. O rótulo vem de observação. O sistema produz apenas features e sugestões de onde observar.

O motivo é concreto: hoje `severity` é função determinística de quatro variáveis brutas (declividade, BSI, areia, argila) via $\Phi = \text{declividade} \times 0,40 + \text{BSI} \times 50 + \Psi_{\text{solo}}$. Treinar com essas features e esse rótulo reconstruiria os limiares 28,0 e 48,0 com acurácia quase perfeita **sem aprender nada sobre erosão**.

2. A bifurcação: detecção ou predição?

O termo "previsibilidade" abre uma escolha que exige montagens de dados incompatíveis:

	Janela da série	O que o modelo aprende
Detecção	vai até a data do rótulo	onde há erosão hoje
Predição	termina antes da data do rótulo, com intervalo de guarda	onde a erosão vai se instalar

Se a série incluir o período até a observação, o modelo pode estar apenas lendo a assinatura da erosão já consumada. É **vazamento temporal** — o primo do vazamento de alvo.

Recomendação: construir os dois modelos.

- **Modelo D (detecção)** — série completa até a observação. Resultado seguro e publicável.
- **Modelo P (predição)** — série encerrada 2 anos antes da observação. A contribuição original.

A comparação entre eles é, por si só, um resultado: mostra **quanto da erosão observada já estava inscrita no histórico espectral anterior**.

3. Etapa 0 — Definição operacional do rótulo (*bloqueante*)

Nenhuma coleta começa antes disto. Rótulo inconsistente limita o desempenho mais do que qualquer escolha de algoritmo ou de feature.

A definição precisa ser: (a) observável pelo instrumento; (b) aplicável por duas pessoas com o mesmo resultado; (c) registrada **antes** de olhar os dados.

Indicador	Campo	Drone MS	Planet 3–5 m
Espessura do horizonte A (trado)	direto	não	não
Exposição do horizonte B (cor do solo)	sim	sim	parcial
Pedestais / raízes expostas	sim	parcial	não
Início de sulcos (microrravinas)	sim	sim	parcial
Deposição de sedimento em sopé	sim	sim	sim
Vigor diferencial da cultura	parcial	sim	sim

Recomendação: critério composto e graduado — *ausente / incipiente / moderada / severa* — registrado em campo e colapsado para binário na modelagem. Permite testar como classificador binário e ordinal, e permite excluir a classe intermediária do treino para afiar a fronteira.

Ponto crítico: confirmar **ausência** é mais difícil que confirmar presença. O critério de negativo precisa ser tão explícito quanto o de positivo, ou "não vi nada" será tratado como "não há".

4. Arquitetura de dados

4.1 O que vem do Earth Engine

Produto	Uso	Resolução
Sentinel-2 L2A (S2_SR_HARMONIZED)	série histórica multibanda, SWIR	10–20 m
Sentinel-1 GRD (SAR)	observação atravessando nuvem , rugosidade	10 m
Landsat 5/7/8/9 (C2 SR)	extensão da série para trás (desde 1984)	30 m
Copernicus DEM GLO-30	declividade, curvatura, acúmulo de fluxo	30 m
CHIRPS diário	identificação de eventos, série desde 1981	~5,5 km
GPM IMERG semi-horário	intensidade — aproxima o I30 do EI30	~10 km
Cartas de solo da Embrapa	classe pedológica e erodibilidade reais	vetorial

Sentinel-1 é a peça que viabiliza o imageamento pós-evento. É o único sensor que garante observação logo após a tempestade. Sensível a rugosidade superficial (sulcos, encrostamento) e a umidade. Ressalva honesta: interpretação difícil, umidade e rugosidade se confundem no retroespalhamento, pré-processamento próprio. É adição metodológica real, não plug-and-play. Verificar a revisita na janela temporal escolhida — a constelação teve degradação entre 2022 e a entrada do S1C.

Embrapa — pré-requisito, não correção. As duas camadas hoje no aplicativo (`parana_solos_20201105` e `brasil_erodibilidade_solo`) são requisições WMS `format=image/png`: imagem decorativa, não consultável. E o

SoilGrids retorna nulo para o Brasil, conforme o próprio teste do projeto registra. Como features de solo são centrais no método, é preciso consultar as cartas **por valor no ponto** (`WMS GetFeatureInfo` ou `WFS GetFeature`), ou ingeri-las como `asset` no GEE e amostrá-las no mesmo `reduceRegion`.

4.2 O que vem do Planet

SuperDove, 8 bandas, 3–5 m, revisita diária. É o que torna os pares de evento viáveis — com Sentinel-2 sozinho, a estação chuvosa do Paraná deixaria poucos pares utilizáveis.

Limitação a assumir: o SuperDove **não tem SWIR** (coastal blue, blue, green I, green, yellow, red, red edge, NIR). E o SWIR é a faixa mais informativa para mineralogia de solo e para distinguir horizonte B exposto.

Planet dá revisita. Sentinel-2 dá SWIR. Complementares; nenhum substitui o outro.

Divisão de papéis daí decorrente:

- **Sentinel-2 / Landsat** → série histórica e assinatura espectral persistente de solo
- **Planet** → pares de evento, onde importa enxergar no dia certo
- **Sentinel-1** → garantia de observação sob nuvem

Detalhes operacionais que mais importam:

- **UDM2** — máscara de qualidade por pixel (clear, cloud, shadow, light_haze, heavy_haze, snow + confiança). Permite filtrar por *fração limpa dentro da AOI*, não pelo percentual de nuvem da cena inteira. Uma cena com 60% de nuvem pode estar limpa sobre o talhão.
- **Clipping no pedido** — confirmar como a cota é contabilizada. Se for por área entregue, clipar muda a escala do consumo: 400 pontos com buffer de 500 m $\approx$ 400 km² por data, contra dezenas de milhares se baixar cenas inteiras.
- **Harmonização com Sentinel-2** — disponível na Orders API. Necessária se Planet e S2 forem combinados na mesma série; sem ela, a diferença entre sensores vira sinal espúrio.
- **APIs:** Data API (busca; item type `PSScene`, assets `ortho_analytic_8b_sr` e `udm2`) e Orders API (pedido, clipping, harmonização, entrega). SDK e CLI em `pip install planet`.

Uso cirúrgico. Planet sobre buffers pequenos ao redor dos pontos amostrais e das áreas de validação, nunca varredura ampla.

4.3 Chuva — e o papel do SIMEPAR

Fonte primária: **CHIRPS diário** (identificação de eventos, série longa) + **GPM IMERG semi-horário** (intensidade). Ambos no GEE, globais, gratuitos.

O IMERG é o ganho relevante sobre o estado atual do projeto: o sub-horário permite estimar a **intensidade máxima em 30 minutos** — o termo I30 do EI30 da RUSLE, que a climatologia mensal de 2001–2020 hoje empregada não consegue fornecer. Chuva de 40 mm em 8 horas e 40 mm em 40 minutos são eventos erosivos completamente diferentes.

SIMEPAR não é essencial, e há razão metodológica para não depender dele. O objetivo é validar um *método*; um método que exige acesso privilegiado à rede de radar de um estado não se reproduz fora do Paraná. CHIRPS e IMERG tornam o método portátil.

Uso recomendado do SIMEPAR, se o acesso vier: **verificar** a qualidade da estimativa satelital de chuva na área de estudo, comparando com estações e radar. Vira contribuição metodológica adicional, sem criar dependência. INMET e ANA/HidroWeb servem ao mesmo propósito e são de acesso livre.

4.4 Credenciais

Manter o padrão atual do aplicativo: setor próprio de configuração, com as chaves em sessão de servidor efêmera referenciada por cookie `httpOnly`, nunca gravadas em disco (`sessionStore.ts`, `ApiTokensManager.tsx`). O padrão foi auditado e está correto. A chave do Planet entra pelo mesmo caminho, ao lado da Service Account do GEE e dos demais tokens.

5. As camadas de features

5.1 Série histórica multibanda — o eixo do método

Por que a série, e não a data única. Uma imagem isolada **não separa** solo recém-gradeado de solo erodido: ambos aparecem como solo exposto. A série separa, porque o gradeado é **transitório** — em 40 dias há dossel — enquanto a mancha erodida é **persistente**: horizonte B exposto tem assinatura própria (mais óxidos de ferro, menos matéria orgânica) e a cultura cresce ali com vigor reduzido, safra após safra.

É essa persistência que a série enxerga e a data única não.

Bandas úteis (Sentinel-2):

Bandas	Papel
B11, B12 (SWIR)	mineralogia e umidade — as mais informativas
B4, B3, B2	cor do solo; razão B4/B2 relaciona-se a óxidos de ferro
B5, B6, B7 (red edge)	estresse da cultura — sinal indireto de perda de solo
B8, B8A (NIR)	vigor e estrutura do dossel

Descartar B1 (aerossol) e B9 (vapor d'água): 60 m e sem informação de solo.

O problema de dimensionalidade. 10 bandas × 12 meses × 6 anos = **720 features** para talvez 400 pontos rotulados. Com $p \gg n$, XGBoost superajusta e as importâncias viram ruído. Compressão obrigatória:

1. **Regressão harmônica por banda** — senoide anual + semianual; guardar offset, amplitude, fase e **tendência linear**. ~5 coeficientes por banda → ~50 features. A tendência de longo prazo no SWIR é, provavelmente, a feature mais informativa do conjunto.
2. **Estatísticas de distribuição** — percentis 10/50/90, amplitude, desvio.
3. **Frequência de exposição** — nº de observações com NDVI abaixo do limiar, maior sequência contínua de solo descoberto, mês modal de exposição.

Lacunas. Série longa terá muitas nuvens. Lacuna fica como NaN — XGBoost trata nativamente — ou é interpolada temporalmente. **Jamais preenchida com constante:** o `unmask()` hoje presente no pipeline (BSI 0,0 / NDVI 0,5) replicado ao longo de 6 anos criaria um padrão artificial que a árvore aprenderia com prazer.

5.2 Composto de solo exposto

Compor usando **apenas as observações em que o pixel estava efetivamente descoberto** (NDVI abaixo do limiar), ao longo de todos os anos disponíveis.

O produto é uma imagem sintética de reflectância do solo, sem cobertura vegetal e sem ruído fenológico — substancialmente superior a qualquer cena única para mapear propriedade de solo e subsolo exposto. Linha de pesquisa consolidada, com trabalho brasileiro relevante (a linha do Demattê, na ESALQ, com o GEOS3 — conferir referências e verificar se há produto pronto para o Paraná).

Ataca de frente o problema que o `inferPedologyClass` hoje tenta resolver por regra sobre granulometria. Roda no mesmo `ImageCollection` do GEE.

5.3 Pares de evento — antes e depois da chuva

A ressalva física. Logo após a chuva o solo está saturado, e solo úmido tem reflectância muito menor em todas as bandas, sobretudo no SWIR. Umidade é o maior confundidor da análise espectral de solos — o escurecimento pode encobrir o contraste que se quer medir.

O que a imagem pós-evento mostra bem: **deposição de sedimento** (leques claros em sopé e em linhas de drenagem), **incisão recente**, **encrostamento**, e **turbidez** em corpos d'água a jusante — bom proxy indireto.

Para erosão *laminar*, o momento mais informativo pode não ser logo após a chuva, mas alguns dias depois, com o solo seco: áreas erodidas mais claras (subsolo), áreas de deposição mais escuras (topsoil acumulado). A secagem revela o que a umidade mascara.

Desenho em três momentos:

T- (antes)	cena limpa mais próxima anterior ao evento
T0 (0-2 dias)	Sentinel-1 garantido + Planet se houver janela -> deposicao, incisao, encrostamento
T+ (7-15 dias)	Planet ou Sentinel-2, solo ja seco -> padrao de redistribuicao

Requisito do pareamento: as cenas precisam ser radiometricamente comparáveis — mesmo sensor, geometria próxima, estágio fenológico semelhante. Senão a diferença medida é o crescimento da cultura, não a chuva.

Montagem retrospectiva, não planejada. Não se planeja imagear depois de uma chuva específica. Faz-se o inverso, sobre o arquivo:

1. varrer CHIRPS/IMERG e listar todos os eventos de alta erosividade (ex.: > 25 mm/dia, ou I30 acima de limiar)
2. para cada evento, buscar no arquivo a cena utilizável mais próxima antes e depois
3. manter apenas pares dentro da janela definida
4. **contar quantos pares utilizáveis realmente restam**

O passo 4 é decisivo e pode ser respondido em uma tarde, **antes** de comprometer o desenho. Se restarem dezenas de pares, é eixo central; se restarem poucos, vira ilustração de caso e o eixo permanece na série histórica.

5.4 Terreno, solo e a feature de mecanismo

Terreno (DEM): declividade, curvatura de perfil e plana, acúmulo de fluxo, índice topográfico de umidade (TWI), posição na vertente.

Solo: classe pedológica e erodibilidade **reais** das cartas da Embrapa.

Feature de mecanismo — cruzando a série espectral com a série de chuva:

```
Σ ( erosividade_t × solo_exposto_t ) sobre toda a serie
```

É, essencialmente, uma RUSLE empírica construída a partir de observação em vez de coeficientes tabelados. Se superar a RUSLE clássica no conjunto de validação, é resultado de dissertação forte e defensável.

5.5 O que NÃO entra na matriz

severity, priorityScore, estimatedSoilLoss, featureType, stratumId e os cinco fatores RUSLE. Todos são funções determinísticas das variáveis brutas — colineares, sem informação adicional, e carregam os defeitos identificados na auditoria (entre eles a inversão do Fator C em relação ao BSI).

6. Desenho amostral

6.1 Frame de elegibilidade

Mantém-se o atual (ESA WorldCover 30/40/60; declividade 3–20%; exclusão de água com buffer de 30 m; exclusão urbana com buffer de 150 m), **acrescido de um critério novo:**

Cobertura temporal mínima — número mínimo de observações válidas na série. Um ponto com 80% de lacunas não serve para treino.

6.2 Estratificação

Os 6 estratos atuais (3 classes de declividade × 2 grupos de erodibilidade) são base adequada. Ampliar para incluir **cobertura/uso** e **faixa de erosividade**, agora que a chuva passa a ser variável e não constante.

6.3 Amostragem por quantis, não Top-N

Mudança conceitual central no aplicativo. Hoje `thinBySpacing()` entrega os pontos de maior score. Para treino é preciso o oposto: **cobrir toda a faixa de Φ** , incluindo deliberadamente os de Φ baixo, que são os candidatos a classe negativa.

6.4 Classe negativa

Amostrar os negativos **do mesmo frame de elegibilidade** dos positivos. Se o negativo cair em floresta ou várzea, o modelo aprende "NDVI alto = sem erosão" — trivial e inútil em lavoura.

6.5 Bloco espacial

Atribuir a cada ponto um bloco espacial, exportado junto. O *thinning* de 1 km não elimina autocorrelação de solo e relevo; k-fold aleatório inflaria a acurácia.

7. Campanha de rotulagem

Fase A	Interpretacao visual em alta resolucao (Planet 3-5 m) 2 interpretes independentes + Kappa de Cohen -> 300-600 pontos, rotulo de qualidade media
Fase B	Campo em subamostra estratificada (~100 pontos) ficha padronizada, ingestao via KoboToolbox -> mede a TAXA DE ERRO da interpretacao visual
Fase C	Treino dos modelos D e P ponderacao ou correcao pelo erro medido em B
Fase D	Drone multiespectral em areas HELD-OUT, voo planejado -> validacao final independente

A Fase B é o que torna a Fase A defensável: sem ela a interpretação visual é opinião; com ela, é medição com incerteza conhecida.

7.1 O drone na Fase D — como escolher as áreas

Com disponibilidade limitada, cada voo precisa render o máximo de informação. Duas exigências:

Incluir o que o modelo prevê como negativo. Se as áreas de validação forem só onde o modelo prevê erosão, mede-se precisão e nunca recall — falsos negativos ficam invisíveis. A seleção deve ser **estratificada ao longo da faixa de predição**, incluindo baixa probabilidade.

Rotulagem cega. Quem interpreta o ortomosaico não pode conhecer a predição do modelo nem o score algorítmico do ponto. O aplicativo deve exportar a lista de voo **sem as colunas de predição**.

O drone é onde o imageamento por evento realmente funciona: voa abaixo da base das nuvens, no dia seguinte à chuva, com resolução centimétrica. A estratégia de par de evento é mais viável no drone que no satélite — vale reservar parte dos voos para isso.

8. Modelagem

- **Matriz:** apenas medição bruta, features temporais comprimidas, chuva e a feature de mecanismo.

- **Validação cruzada espacial** por blocos. Para o Modelo P, **também** separação temporal.
- **Linha de base:** RUSLE corrigida, e o resultado do Modelo D como referência para o Modelo P.
- **Métricas:** AUC-PR e reporte explícito da prevalência. Com classe desbalanceada, acurácia é enganosa.
- **Regularização e seleção de features:** com ~50–70 features e ~400 amostras, é obrigatória. Aninhar a seleção dentro da validação cruzada, nunca antes dela.

9. O aplicativo — escopo

*Não é um eleitor de focos de erosão. É um **desenhador de amostragem e gerenciador de campanha de rotulagem**, sobre duas vias de ingestão.*

Função	Estado
Frame de amostragem (elegibilidade)	existe; acrescentar cobertura temporal mínima
Estratificação	existe; ampliar
Amostragem por quantis	mudar (hoje é Top-N)
Extração de série temporal no GEE	construir
Ingestão Planet (busca, UDM2, pedido com clipping)	construir
Deteção de eventos de chuva (CHIRPS/IMERG)	construir
Export de plano de campo e de voo, cego	parcial
Ingestão de rótulo (Kobo, interpretação, drone)	koboParser é boa base
Matriz de treino com proveniência por variável	construir
RUSLE como linha de base	existe, precisa das correções da auditoria

9.1 Duas vias de ingestão

	GEE	Planet
Dados	S1, S2, Landsat, DEM, CHIRPS, IMERG, solo	PlanetScope
Processamento	server-side, sem download	busca → pedido → download → local
Cota	computação	área entregue

Não é problema, mas é uma segunda via a projetar — e reforça o uso cirúrgico do Planet.

9.2 Aproveitar do código atual

Manter: `eligibilityMask` + `eligibilityConstants`, `stratification`, `spatialThinning`, `aoiTiling`, `koboParser` + `KoboFieldImport`, `spatialMatcher.py` + base fundiária, `sessionStore` / `localOnly` / `isSyntheticPoint`, `xlsxWriter` e a infraestrutura de export.

Reposicionar ou descartar: `severity` e `priorityScore` como resultado (viram critério interno); defaults de `parsers.ts` (substituir por ausência explícita); `inferPedologyClass` (substituir pela carta real da Embrapa); perda de solo como produto (vira linha de base); bônus CAR no score exportado (separar em `selectionScore` interno).

10. Sequência de execução

ETAPA 0	Definicao operacional do rotulo	BLOQUEANTE
ETAPA 1	Testes de viabilidade (baratos, antes de decidir) 1a Primeiro contato com a API do Planet: busca sobre um ponto, cobertura limpa por UDM2 na AOI 1b Pares de evento: quantos realmente existem? CHIRPS/IMERG x arquivo S1/S2/Planet	
ETAPA 2	Features de verdade Solo real da Embrapa - chuva CHIRPS/IMERG Serie historica comprimida - composto de solo exposto	
ETAPA 3	Amostragem para treino Quantis de PHI - negativos do mesmo frame Blocos espaciais - export de campo CEGO	
ETAPA 4	Campanha de rotulagem (Fases A e B)	
ETAPA 5	Modelagem: Modelo D e Modelo P	
ETAPA 6	Validacao final por drone (Fase D), voo planejado	

A Etapa 1 vale ser feita **antes** de qualquer compromisso de desenho: define se o imageamento por evento é eixo central ou ilustração.

11. Pontos para decidir com o orientador

#	Questão	Impacto
1	Definição operacional de presente / ausente	Determina tudo o que vem depois
2	Binário ou ordinal (ausente / incipiente / moderada / severa)	Desenho do modelo e da ficha de campo
3	Modelo D, Modelo P, ou os dois	Montagem da série e do intervalo de guarda
4	Extensão da série: só Sentinel-2 (~2017+) ou incluir Landsat (1984+)	Resolução × profundidade histórica
5	Unidade de predição: pixel de 10 m, de 30 m, ou talhão	Muda features, rótulo e validação
6	Domínio de validade: só 3–20% de declividade e uso agrícola?	Restringe a inferência; precisa ser declarado
7	Nº de pontos de campo e de voos viáveis no cronograma	Fixa o teto de desempenho do modelo
8	A RUSLE entra como comparação ou sai do escopo	Define se as correções da auditoria são necessárias

12. Riscos principais

1. **Rótulo mal definido** — risco nº 1, e não é técnico. Nenhum ajuste de modelo compensa rótulo inconsistente.
2. **Vazamento de alvo** — usar quantidade calculada pelo sistema como rótulo produz acurácia excelente e conhecimento zero.
3. **Vazamento temporal** — série que alcança a data do rótulo transforma predição em detecção sem avisar.
4. **Dimensionalidade** — 720 features para 400 amostras. Compressão e regularização não são opcionais.
5. **Preenchimento de lacuna com constante** — em série longa, cria padrão artificial que a árvore aprende.
6. **Autocorrelação espacial** — k-fold aleatório infla a acurácia.
7. **Cota do Planet** — sem clipping, um único download consome o mês.
8. **Custo de inferência** — 50 features temporais para predizer no estado inteiro exige planejamento no GEE.

9. **Viés de confirmação** — mitigado por rotulagem cega, inclusive no drone.

10. **Amostra pequena** — o teto do modelo é fixado pelo número de rótulos, não pela qualidade do código.

Documento v2, derivado da auditoria de 08/09/2026 e das decisões tomadas na mesma data. As fontes externas citadas (Planet/SuperDove, CHIRPS, GPM IMERG, HLS/Landsat, cartas da Embrapa, GEOS3) precisam de confirmação de cobertura, disponibilidade e condições de uso antes de incorporação definitiva ao desenho.